

浏览器自动运营 Agent / RAG / 通用 Agent 平台面试题单

候选人：_____ 面试官：_____ 时间：_____

面试目标

验证候选人是否真的具备：

- RAG：文档解析、切分、召回、重排、上下文组装、评测与优化能力。
- 浏览器自动运营 Agent：Playwright/Selenium、账号态、抓取、发布、反爬、人工接管。
- 通用 Agent 平台：Runtime、Harness、工具注册、上下文工程、checkpoint/resume、权限审计。
- 工作流平台：能否设计可控的状态流、节点、重试、兜底、Coze/Dify/LangGraph 取舍。
- Agent：工具调用、记忆、权限、安全边界、可观测和工程落地能力。
- 加分项：了解 LLM 部署、训练、蒸馏、RL 后训练。

60 分钟流程

时间	模块	目标
0-5 分钟	开场确认	到岗时间、实习周期、最熟项目
5-20 分钟	项目深挖	验证个人职责、项目深度、指标真实性
20-35 分钟	方向专项	浏览器自动化 / Agent Runtime / RAG / 工作流按项目选择
35-50 分钟	工程落地	看权限、审计、checkpoint、失败恢复、测试和部署
50-55 分钟	加分项	部署、训练、蒸馏、RL 后训练
55-60 分钟	候选人提问	观察表达、关注点和沟通方式

一、开场确认

1. 你现在是否还在看实习机会？
2. 最早什么时候能到岗？每周能实习几天？能持续多久？
3. 你简历里最想展开讲的浏览器自动化、Agent 平台、RAG 或工作流项目是哪一个？

记录：

二、项目深挖

必问题：

1. 请画一下这个项目的整体架构，从用户输入到最终输出完整走一遍。
2. 哪些模块是你独立做的？哪些是团队已有、框架已有或参考开源项目的？
3. 项目里最难的问题是什么？你当时有哪些备选方案？为什么选最终方案？
4. 简历里的效果指标怎么测出来的？测试集多大？baseline 是什么？
5. 如果重新做一版，你会删掉或重构哪个模块？

追问方向：

- 有没有线上用户、真实数据或 demo？
- 有没有失败样例？最后怎么定位？
- 有没有代码、日志、trace、评测脚本可以证明？

记录：

三、RAG 专项

必问题：

1. 一个企业知识库 RAG，从文件上传到最终回答，完整链路有哪些步骤？
2. PDF、Word、网页、图片混合文档怎么解析？什么时候需要 OCR 或 VLM？
3. chunk size、overlap、父子分块、语义分块分别解决什么问题？你怎么选？
4. BM25、向量检索、混合检索、RRF、Cross-Encoder Rerank 的作用和代价是什么？
5. 如何判断一次回答不好，是召回问题、排序问题、上下文组装问题，还是生成问题？

进阶追问：

1. Query Rewrite、HyDE、Multi-Query 分别适合什么场景？有什么风险？
2. 如何设计 RAG 评测集？Hit@K、MRR、context precision、faithfulness 各看什么？
3. RAG 回答出现幻觉，你会怎么定位和修复？
4. 多轮对话里，历史消息和检索上下文怎么拼接，避免 token 爆炸？

记录：

四、浏览器自动运营 Agent 专项

必问题：

1. 如果做“小红书/网页内容运营 Agent”，从登录、抓取、分析、生成、审核到发布，你会怎么拆任务流？
2. Playwright 和 Selenium 在动态页面、等待策略、稳定性、并发和调试上有什么差异？
3. 如何维护登录态、Cookie、localStorage、代理、设备指纹和账号风控边界？
4. 遇到验证码、滑块、反爬、请求限流或页面 DOM 频繁变化，怎么设计降级和人工接管？
5. 自动发布内容前，如何做敏感词、重复内容、格式、图片、链接和权限校验？

记录：

五、通用 Agent 平台 / Claw 类专项

必问题：

1. 类 Claw / WorkBuddy / 龙虾的平台，核心模块有哪些？
2. Agent Runtime 主循环怎么设计？模型输出、工具解析、工具执行、observation 回填、final 输出之间如何流转？
3. 工具注册中心如何设计 schema、权限、超时、幂等、重试和风险等级？
4. checkpoint / resume 需要保存哪些状态？恢复时如何判断 workspace、memory、tool result 是否不一致？
5. 如何防止 Agent 执行危险 shell、越权文件访问、重复工具调用或泄露敏感信息？

记录：

六、Agent / 工作流 / Coze 专项

必问题：

1. ReAct、Plan-and-Execute、Reflection、Multi-Agent 分别适合什么任务？
2. 用 LangGraph 设计一个“问答 + 查数据库 + 建工单”的状态图，节点和边怎么定义？
3. 工具调用的 schema 怎么设计？如何处理参数缺失、参数错误、工具超时？
4. 工具调用失败后，Agent 应该重试、换工具、问用户还是兜底？怎么判断？
5. Agent 的短期记忆、长期记忆、用户画像和任务状态有什么区别？
6. Coze/Dify 适合做哪些节点？哪些逻辑必须自研？
7. 工作流失败时，如何做重试、跳过、人工确认和回滚？

进阶追问：

1. 什么情况下需要多 Agent？多 Agent 相比单 Agent 的问题是什么？
2. checkpoint / resume 在长任务里解决什么问题？哪些状态必须持久化？
3. 如何防止 Agent 调危险工具、越权访问、重复调用或泄露敏感信息？
4. 如何做 Agent 可观测性？你会记录哪些 trace 字段？

记录：

七、工程落地

必问题：

1. FastAPI / SSE / WebSocket 在大模型流式输出里怎么选？
2. 一个 RAG / Agent 服务上线，你会怎么做 Docker 镜像、配置、日志和监控？
3. 向量库、关系库、Redis 分别存什么？哪些数据不能只放向量库？
4. 高并发下，embedding、rerank、LLM 调用哪个最容易成为瓶颈？怎么优化？
5. 如果一次 Agent 任务有 30 次工具调用，怎么控制延迟、成本和失败率？

记录：

八、加分项

任选 3-5 个问题：

1. LoRA 和 QLoRA 的区别是什么？什么时候需要微调，什么时候只做 RAG？
2. SFT 数据怎么构造？如何清洗低质量样本？
3. 训练时你会关注哪些指标？loss 下降是否一定代表效果变好？
4. vLLM、Ollama、Transformers 本地推理各有什么取舍？
5. 知识蒸馏解决什么问题？学生模型和教师模型怎么评估？
6. RLHF、DPO、GRPO 的基本区别是什么？
7. 医疗、金融等高风险场景做安全对齐，你会怎么设计 reward 或偏好数据？

记录：

九、现场设计题

题目：设计一个“浏览器自动运营 Agent + 通用 Agent 工作台”。

要求候选人覆盖：

- 浏览器登录、抓取、表单操作、内容发布和人工接管。
- Playwright/Selenium 执行器、截图、DOM 解析、等待策略和异常恢复。
- 工具注册、权限控制、审计日志和风险操作审批。
- Agent Runtime、上下文工程、短期/长期记忆和 checkpoint/resume。
- RAG 素材库、历史案例库、运营知识库的检索、重排和引用。
- Coze/Dify 快速搭建和自研 LangGraph/Runtime 的边界。
- 评测指标、线上监控、成本和延迟控制。

追问：

1. 如果浏览器任务执行到一半页面结构变了怎么办？
2. 如果自动发布前发现内容命中敏感词或低置信度怎么办？
3. 如果同一账号连续失败 3 次，系统如何降级和保护账号？
4. 如果老板要求 1 周上线 MVP，你会砍掉哪些功能？
5. 如果线上成本或封号风险超预算，你先优化哪三个点？

记录：

十、评分表

维度	分值	得分	备注
浏览器自动化/运营场景	20		
Agent Runtime/平台能力	25		
RAG/知识库	15		
工作流/Coze 类平台	15		
工程落地	15		
项目真实性	5		
表达与学习能力	5		
总分	100		

十一、结论

结论：

- ☐ 通过，进入下一轮
- ☐ 备选，补充确认后决定
- ☐ 暂不推进

理由：

后续动作：
