

AI Agent / RAG 实习生面试题单

候选人：_____ 面试官：_____ 时间：_____

面试目标

验证候选人是否真的具备：

- RAG：文档解析、切分、召回、重排、上下文组装、评测与优化能力。
- 工作流：能否设计可控的状态流、节点、重试、兜底、checkpoint。
- Agent：工具调用、记忆、权限、安全边界、可观测和工程落地能力。
- 加分项：了解 LLM 部署、训练、蒸馏、RL 后训练。

60 分钟流程

时间	模块	目标
0-5 分钟	开场确认	到岗时间、实习周期、最熟项目
5-20 分钟	项目深挖	验证个人职责、项目深度、指标真实性
20-35 分钟	RAG 专项	看是否懂完整链路和优化方法
35-50 分钟	Agent / 工作流	看是否能设计可控、可落地的 Agent
50-55 分钟	加分项	部署、训练、蒸馏、RL 后训练
55-60 分钟	候选人提问	观察表达、关注点和沟通方式

一、开场确认

1. 你现在是否还在看实习机会？
2. 最早什么时候能到岗？每周能实习几天？能持续多久？
3. 你简历里最想展开讲的 Agent / RAG 项目是哪一个？

记录：

二、项目深挖

必问题：

1. 请画一下这个项目的整体架构，从用户输入到最终输出完整走一遍。
2. 哪些模块是你独立做的？哪些是团队已有、框架已有或参考开源项目的？
3. 项目里最难的问题是什么？你当时有哪些备选方案？为什么选最终方案？
4. 简历里的效果指标怎么测出来的？测试集多大？baseline 是什么？
5. 如果重新做一版，你会删掉或重构哪个模块？

追问方向：

- 有没有线上用户、真实数据或 demo？
- 有没有失败样例？最后怎么定位？
- 有没有代码、日志、trace、评测脚本可以证明？

记录：

三、RAG 专项

必问题：

1. 一个企业知识库 RAG，从文件上传到最终回答，完整链路有哪些步骤？
2. PDF、Word、网页、图片混合文档怎么解析？什么时候需要 OCR 或 VLM？
3. chunk size、overlap、父子分块、语义分块分别解决什么问题？你怎么选？
4. BM25、向量检索、混合检索、RRF、Cross-Encoder Rerank 的作用和代价是什么？
5. 如何判断一次回答不好，是召回问题、排序问题、上下文组装问题，还是生成问题？

进阶追问：

1. Query Rewrite、HyDE、Multi-Query 分别适合什么场景？有什么风险？
2. 如何设计 RAG 评测集？Hit@K、MRR、context precision、faithfulness 各看什么？
3. RAG 回答出现幻觉，你会怎么定位和修复？
4. 多轮对话里，历史消息和检索上下文怎么拼接，避免 token 爆炸？

记录：

四、Agent / 工作流专项

必问题：

1. ReAct、Plan-and-Execute、Reflection、Multi-Agent 分别适合什么任务？
2. 用 LangGraph 设计一个“问答 + 查数据库 + 建工单”的状态图，节点和边怎么定义？
3. 工具调用的 schema 怎么设计？如何处理参数缺失、参数错误、工具超时？
4. 工具调用失败后，Agent 应该重试、换工具、问用户还是兜底？怎么判断？
5. Agent 的短期记忆、长期记忆、用户画像和任务状态有什么区别？

进阶追问：

1. 什么情况下需要多 Agent？多 Agent 相比单 Agent 的问题是什么？
2. checkpoint / resume 在长任务里解决什么问题？哪些状态必须持久化？

3. 如何防止 Agent 调危险工具、越权访问、重复调用或泄露敏感信息？
4. 如何做 Agent 可观测性？你会记录哪些 trace 字段？

记录：

五、工程落地

必问题：

1. FastAPI / SSE / WebSocket 在大模型流式输出里怎么选？
2. 一个 RAG / Agent 服务上线，你会怎么做 Docker 镜像、配置、日志和监控？
3. 向量库、关系库、Redis 分别存什么？哪些数据不能只放向量库？
4. 高并发下，embedding、rerank、LLM 调用哪个最容易成为瓶颈？怎么优化？
5. 如果一次 Agent 任务有 30 次工具调用，怎么控制延迟、成本和失败率？

记录：

六、加分项

任选 3-5 个问题：

1. LoRA 和 QLoRA 的区别是什么？什么时候需要微调，什么时候只做 RAG？
2. SFT 数据怎么构造？如何清洗低质量样本？
3. 训练时你会关注哪些指标？loss 下降是否一定代表效果变好？
4. vLLM、Ollama、Transformers 本地推理各有什么取舍？
5. 知识蒸馏解决什么问题？学生模型和教师模型怎么评估？
6. RLHF、DPO、GRPO 的基本区别是什么？
7. 医疗、金融等高风险场景做安全对齐，你会怎么设计 reward 或偏好数据？

记录：

七、现场设计题

题目：设计一个企业内部“知识库问答 + 工单处理 Agent”。

要求候选人覆盖：

- 文档解析和知识库入库。
- 混合检索和重排。

- 用户意图识别和工作流路由。
- 工具调用和权限控制。
- 多轮会话记忆。
- 失败重试和人工兜底。
- 评测指标和线上监控。
- 部署方案和成本优化。

追问：

1. 如果召回结果为空怎么办？
2. 如果工具返回数据和文档知识冲突怎么办？
3. 如果用户要求删除知识库中的隐私数据怎么办？
4. 如果老板要求 1 周上线 MVP，你会砍掉哪些功能？
5. 如果线上成本超预算，你先优化哪三个点？

记录：

八、评分表

维度	分值	得分	备注
RAG 深度	25		
Agent / 工作流	25		
工程落地	20		
项目真实性	15		
加分项	10		
表达与学习能力	5		
总分	100		

九、结论

结论：

- ☐ 通过，进入下一轮
- ☐ 备选，补充确认后决定
- ☐ 暂不推进

理由：

后续动作：

推荐话术

电话联系候选人

首次接通

你好，请问是「候选人姓名」吗？

我这边是 AI Agent / RAG 应用开发实习岗位的面试安排人。我们看了你的简历，觉得你在 RAG、Agent 或 workflow 方向的经历和岗位比较匹配，想简单确认一下你现在是否还在看实习机会。

如果候选人表示还在看：

方便确认几个信息吗？

1. 你最早什么时候可以开始实习？
2. 每周可以实习几天？
3. 大概可以持续几个月？
4. 你简历里的 Agent / RAG 项目，技术面时可以展开讲吗？

收尾：

好的，我这边记录一下。如果时间合适，我们会安排一次技术面，主要聊你的项目、RAG、Agent workflow 和工程落地。稍后我会通过短信或邮件把面试安排发给你。

未接电话后的短信

你好，我是 AI Agent / RAG 应用开发实习岗位的面试安排人。看到你的简历和岗位方向比较匹配，刚才电话联系未接。想确认你目前是否还在看实习机会，以及是否方便安排一次技术面。方便的话可以回复我，谢谢。

候选人不方便接电话

没关系，你方便的时候可以回拨，或者直接短信回复这几个信息：是否还在看实习、最早到岗时间、每周可实习天数、可持续多久。我们再看是否安排技术面。

邮件确认面试

标题：

AI Agent / RAG 应用开发实习岗位面试邀请

正文：

你好，

我们看了你的简历，觉得你的 RAG / Agent / workflow 相关经历和岗位方向比较匹配，想邀请你参加一次技术面试。

面试内容主要包括：

1. 简历项目深挖
2. RAG 链路设计与优化
3. Agent 工作流、工具调用、记忆和工程落地
4. LLM 部署、训练或后训练相关了解情况

请回复你方便的面试时间段，我们再确认具体安排。

谢谢。

微信确认

你好，我是刚才电话联系你的面试安排人。

这边同步一下岗位方向：AI Agent / RAG 应用开发实习。技术面主要会聊你的项目经历、RAG、Agent 工作流和工程落地。

请你发一下方便面试的时间段，我来协调安排。

面试开场

你好，今天面试大概 60 分钟。我们主要不考八股，重点围绕你的项目展开，看看你对 RAG、Agent 工作流、工具调用和工程落地的理解深度。

如果有你不确定的地方可以直接说不确定，我们更关注你怎么拆问题、怎么做取舍。

项目深挖转场

你选一个最熟的 Agent 或 RAG 项目来讲就行。

先不用讲太多背景，重点讲清楚：用户输入进来后，系统怎么处理，经过哪些模块，最后怎么输出结果。

追问真实性

这个模块具体是你自己写的吗？

如果我现在看代码，你会让我先看哪几个文件？

你提到的指标是怎么测出来的？测试集有多少条？有没有 baseline？

追问设计能力

如果这个项目要上线给 100 个真实用户用，你最担心哪三个问题？

如果只能保留一周内能上线的 MVP，你会砍掉哪些功能？

如果线上回答质量突然下降，你会从哪里开始排查？

面试收尾

我这边主要问题问完了。你可以问一下岗位、团队或者后续流程。

我们会综合项目深度、工程能力、实习时间和岗位匹配度做判断，后续会再同步结果。

通过后通知

你好，你这轮技术面反馈不错，我们想继续推进下一轮。下一轮会更偏系统设计和项目深挖，重点看 RAG / Agent 工作流的工程落地能力。请发一下你接下来方便的时间段。

暂缓或不合适通知

你好，感谢你参加这次面试。综合这次沟通和岗位要求，我们这边暂时不继续推进。主要原因是当前岗位更需要 RAG、Agent 工作流和工程落地经验更强的候选人。祝你后续求职顺利。