

雷君帆

16627609675 | 2137601181@qq.com

求职意向：Agent 应用开发



教育经历

2023.09-2027.06

河南大学(双一流院校)

软件工程

专业技能

- 熟练使用 Python 及 FastAPI、Django 等框架进行后端开发与异步接口设计；熟悉 MySQL、ChromaDB、Qdrant、Elasticsearch 等数据库与检索系统，具备 RAG 全流程落地经验
- 掌握 LangChain、LangGraph、DeepAgents 等 Agent 框架，能独立搭建 ReAct 自主决策链路及 DAG 工作流编排；具备多意图路由、中间件动态提示词切换、分层记忆系统设计等 Agent 工程化能力、
- 熟练使用通义千问、DeepSeek 等国产大模型 API，具备 Prompt Engineering、RAG 全链路评测 (Recall/MRR/NDCG/RAGAS) 及知识库构建调优经验；熟练使用 Git 进行版本管理与团队协作

项目经历

2026.04-2026.06

智扫通 智能客服

项目简介：基于 LLM + RAG + Agent 架构的扫地机器人智能客服系统，集成多意图动态路由、BM25+Embedding 混合检索、三层记忆系统与全链路 RAG 评测，用户通过自然语言提问，系统自主调用工具、检索知识库生成专业回答，支持咨询问答、故障排查、维护保养、报告生成、选购推荐五大场景的无感切换。

- 三层记忆系统：**短期记忆采用滑动窗口策略，长期记忆采用事实抽取 + Embedding 双阶段去重 (Hash 精确去重 + 余弦相似度语义去重)，持久化存储；引入 TTL + Importance 动态衰减机制，旧记忆权重随时间自动衰减，保证记忆有效性与存储效
- BM25 + Embedding 混合检索：**在纯向量检索基础上引入 BM25 关键词检索，向量通道捕获语义相关 ("扫地机卡住"→"缠绕故障")，BM25 通道捕获精确匹配 ("E4 错误码"→命中故障排除文档)；通过 RRF (Reciprocal Rank Fusion) 融合排序，Top-5 召回准确率从 93% 提升至 98%%
- 意图识别与动态路由：**设计基于规则 + 关键词的轻量意图分类器，在主 Agent 执行前完成意图预判 (咨询问答/故障排查/维护保养/报告生成/选购推荐)，通过中间件将 intent 注入运行时 context，动态切换对应场景提示词与工具集，场景切换成功率 98%，对话中无感切换身份
- RAG 全链路评测体系：**基于知识库构建 50 条 Golden Query 黄金测试集，从 召回率、平均倒数排名、排序质量 等检索维度与 忠实度、答案相关性 等生成维度对 RAG 链路进行全链路评测；对比不同 chunk_size 配置下的检索效果，确定最优参数组合，知识库 Top-5 召回准确率 94%

2026.03-2026.04

智库 NL2SQL 智能问答系统

项目简介：基于 LangGraph 的 Text-to-SQL 数据问答系统，用户用自然语言提问数据相关问题 (如"统计各品类销售额占比" "某某商品销售趋势")，系统自动完成语义理解、信息召回、SQL 生成与执行，返回查询结果。

- LangGraph 智能体编排：**搭建 12 节点 DAG 工作流，实现"关键词提取 → 多路并行召回 (字段/指标/字段值) → 信息合并与精排 → SQL 生成 → 校验修正 → 执行"全链路自动化，支持并行节点执行与条件分支跳转全链路端到端耗时 <8s，首次执行成功率 97%
- 多策略混合检索：**结合 Qdrant 向量检索 (字段/指标语义召回)、ES 全文检索 (字段值精准匹配) 和 LLM，字段/指标召回准确率 91%，字段值精准匹配率 96%
- SQL 自动校验与修正：**实现 validate → correct 的有限次重试机制，LLM 生成的 SQL 经语法校验失败后携带错误信息进入修正节点，利用原始查询意图与数据库错误驱动 LLM 重新生成，直至通过或到最大重试次数。首轮 SQL 合法率 97%，经修正后最终通过率提升至 99% (平均重试 0.3 次)
- LLM 信息精排：**召回阶段后增加 LLM 筛选节点，根据用户查询语义对候选表和指标进行二次精排，过滤无关信息。减少传递给 SQL 生成的无关上下文 40%，SQL 准确率提升 12%