

求职意向：ai应用开发

姓名：邵金学

期望城市：北京/深圳

年龄：20岁

院校：济南大学

手机号码：13123652935

邮箱：taijinxue@gmail.com



专业技能 Campus experience

1. 熟悉 Python 后端开发（FastAPI、asyncio、Pydantic），熟练掌握异步并发调度、同异步桥接、指数退避重试等高性能编程范式。
2. 熟悉 RAG 检索增强生成全链路（文档切片、Embedding、HNSW 混合检索、Cross-Encoder Rerank、Int8 量化、Metadata 过滤、dense_weight 权重调优）。
3. 熟悉 Prompt Engineering，具备提示词版本管理、自动化评测、负样本优化经验；熟练运用 Pydantic Schema / JSON Mode 实现 LLM 结构化输出。
4. 熟悉 LLM 推理性能调优，深入理解 Prefix Caching / KV Cache 机制，具备 TTFT 优化、Token 分级控制、多模型动态路由等生产级经验。
5. 熟悉 大模型微调全流程（数据清洗 → SFT → DPO），掌握 QLoRA/LoRA 参数高效微调（LLaMA-Factory、火山引擎方舟平台），理解 RLHF 与 DPO 的差异及适用场景。
6. 熟悉 LangGraph/LangChain 工作流编排（SubGraph 子图、Checkpoint 状态持久化、SSE 流式输出、LangSmith 全链路追踪）。
7. 熟悉 RTC 实时语音链路（ASR 语音识别、TTS 语音合成与声音复刻），掌握 FEC 前向纠错、自适应 Jitter Buffer 等弱网优化策略。
8. 熟悉 后端服务治理（SlowAPI 限流、熔断降级、优雅关闭、健康检查），具备 structlog 结构化日志与 request_id 链路追踪经验。
9. 熟悉 PostgreSQL、向量数据库；熟悉模型评估体系（BLEU/ROUGE/语义相似度/A/B 盲评/Cohen's Kappa）。
10. 了解 Docker 容器化部署、Linux、Git；了解前端 SSE 流式解析（ReadableStream）、Mock 体系设计。

工作经历 Internship experience

杭州五维数据有限责任公司

ai应用开发工程师

2025.6-2026.6

1. 参与公司 AI 战略的技术选型与架构设计，主导大模型（LLM）在智能客服、自媒体营销、销售导购等核心业务场景的落地。
2. 攻坚 RAG 检索优化、Agent 工作流编排、模型微调（SFT/DPO）及 RTC 语音流处理等核心技术难点，平衡模型推理性能与成本。
3. 优化团队工程效能，搭建 AI 评测体系与可视化调试环境，将团队整体迭代周期缩短 50% 以上。
4. 参与公司国内外电商平台（C 端商城、B 端后台管理系统、ERP 订单流转系统）的前后端日常迭代与架构设计，采用 React + Node.js 技术栈进行全栈开发。
5. 完成 Docker 容器化部署，编写 CI/CD 流水线脚本，实现测试、预发、生产环境的自动化发布，显著降低线上故障率。



Ai实时语音对话-智能客服

2025.7 ~ 2026.1

- 依托Prompt Pilot管理提示词，搭建评测集实现自动化评分与版本比对，优化负样本提示词，沉淀优质数据支撑模型精调，保障回复准确一致。
- 自定义知识库切片解决语义截断问题，融合混合检索、Int8量化及标签过滤机制，实现存储占用降低75%。
- 针对语音场景优化检索策略，引入轻量重排模型动态调优权重，提升专有名词命中率，检索速度提升4倍。
- 优化LLM推理链路，依托前缀缓存与KV Cache机制，将复杂RAG场景TTFT从15s压缩至2s内，完成业务模型选型与资源优先级调优。
- 搭建AI可视化开发评测环境，借助公网映射解决语音回调调试问题，优化服务热更新策略，将重启耗时从10s降至2s，提升团队迭代效率。
- 优化RTC语音链路，基于ASR识别用户情感、TTS声音复刻实现情绪化回复，通过弱网纠错优化，实现高丢包环境下语音对话流畅无中断。
- 搭建Token分级控制模型，基于业务数据动态配置推理参数，有效提升单请求Token利用率。

自媒体智能内容运营系统

2026.1 ~ 2026.5

- 基于LangGraph搭建多阶段内容生成 workflow，拆分独立业务单元，通过状态持久化支持单节点回滚与增量重试，细化故障恢复粒度。
- 设计链路上下文管理机制，全链路采集Token消耗、延迟、错误率等指标，结合云平台定价完成成本核算，支撑模型与资源调优。
- 深度集成SSE流式输出，捕获Token级实时流，大幅降低用户端TTFT，同时保障流式与非流式数据结构一致。
- 优化图片批量生成逻辑，通过异步并发改造+指数退避重试，解决服务抖动问题，内容生成耗时缩减70%。
- 实现多模型动态路由，按需分发轻重任务，通过结构化输出强约束解决兼容问题，保质前提下降低40%推理成本。
- 设计环境变量Mock开关实现服务解耦，搭配可视化评测与公网映射调试，大幅提升本地调试效率，缩短团队迭代周期。
- 接入LangSmith全链路可观测能力，结合结构化日志与请求ID关联，将线上问题定位从小时级压缩至分钟级。
- 实现接口限流与熔断器降级机制，搭配健康检查与优雅关闭能力，保障容器化部署下服务高可用。



教育背景 Educational background

2024.09-2028.06

济南大学

金融数学



自我评价

- 工作积极主动、工作效率高、责任心强、注重细节、追求完美。
- 能及时进行思考与总结,对相关知识进行沉淀与分享。
- 喜欢钻研技术、学习源码,经常利用业余时间进行学习。
- 喜欢打篮球、弹吉他、弹钢琴 为人乐观大方,遇事沉着稳重。