

吴孔利

意向岗位: ai 大模型应用开发 agent 开发

性别: 男
电话: 15870846204

年龄: 21
邮箱: 3366766581@qq.com

教育经历

2023.9-2027.6

软件工程

证书: CET-4

东华理工大学

统招本科

实习经历

2026.2-2026.4

江西世龙供应管理有限公司

ai开发实习生

参与项目描述: AI面试平台后端项目, 主要服务海外学生求职场景。项目基于FastAPI + PostgreSQL + Redis + Celery + Docker技术栈, 重点实现AI能力接入与工程化部署, 通过简历智能解析、用户认证、面试流程自动化等功能, 帮助用户提升求职效率。项目具备完整的认证体系、异步任务机制、接口分层设计和AI模型服务集成能力, 为AI面试功能的稳定落地提供后端支撑。

项目主要职责:参与用户认证模块开发, 完成注册、登录、JWT 刷新、邮箱验证, 密码重置等核心接口实现使用 Redis+Celery处理验证码与邮件异步任务, 提升接口响应效率与系统稳定性参与 Docker, 本地环境配置及服务联调, 支持项目开发与测试环境运行

项目经历

2026.1-2026.3

汇智工作协助系统 (基于 Agent+RAG 混合架构的智能问答系统)

项目简介: 面向企业内部知识管理的智能问答系统, 围绕“文档上传 -> 智能切片 -> 向量化入库 -> 混合检索 -> RAG 增强生成 -> Agent 自主推理”构建完整闭环, 支持文档管理、多格式解析、混合检索、RAG 问答、Agent 自主推理, 并提供流式 SSE 响应。

技术实现: • FastAPI + SQLAlchemy(async) + MySQL/SQLite 搭建后端, 支持流式 SSE 输出

- Ollama / OpenAI / DeepSeek 多模型 API, 实现 RAG 增强问答与 Agent 自主推理
- Qdrant + BGE-M3(1024维) 构建混合检索引擎, 采用向量语义检索 + jieba TF-IDF 关键词提取 + MatchText 全文检索三路召回, 通过 RRF 倒数排序融合统一排序, 再经 Cross-Encoder 重排器对 query-doc 联合编码精排, 将检索召回率从纯向量的 65% 提升至 93%。
- Agent搭建智能推理引擎, 内置4种专用工具并实现异常自动降级为纯RAG兜底。系统在生产环境平均响应时间1.3秒, 支持60并发请求; 工具调用成功率99.6%, 异常降级覆盖率达100%; RAG检索Top-5准确率92%。
- Docker Compose 编排 Nginx + FastAPI + Redis, 集成 Prometheus 全链路可观测

GitHub: <https://github.com/yanbaibai12/enterprise-knowledge-rag-agent>

2025.3-2026.5

行业周报多 Agent 智能生成系统 (基于 Multi-Agent 协作的自动采编平台)

项目简介: 面向行业研究场景的智能周报生成平台, 围绕“LLM 动态任务拆解 -> 互联网并行搜索 -> 流式撰写输出 -> 任务持久化恢复”构建完整闭环, 支持多行业模板、异步任务管理与服务重启恢复。

技术实现: • FastAPI + SQLAlchemy(async) + PostgreSQL + Redis 搭建后端, 支持流式 SSE 输出与 WebSocket 实时进度推送

- Ollama / OpenAI / DeepSeek 等多模型 API, 通过 langchain-openai 统一适配, LLM 调用集成超时重试 (120s/2 次) 与断路器熔断保护, JSON 解析失败自动正则提取降级
- LangGraph 设计多 Agent 协作架构 (Orchestrator -> Researcher -> Editor -> Reviewer), 融合为统一流水线, 支持 HITL人工审核中断与恢复
- 实现了异步任务三级持久化架构 (Redis -> PostgreSQL -> 内存), 任一写入成功即保证状态不丢失, 服务重启自动恢复未完成任务
- 设计了 LLM 动态搜索拆解机制: 将用户意图拆解为政策/公司/投融资/趋势四维度关键词, 回退静态行业模板兜底, 并行 asyncio.gather 执行搜索
- Docker Compose 编排四容器服务, 暴露 Prometheus 指标端点+ loguru 结构化日志, 覆盖 HTTP/Agent/LLM/Search 四维度监控

相关技能

LLM 应用: 熟悉主流大模型 API 接入、Prompt Engineering 设计与优化; 掌握 Claude Code、Codex 等 Agent 工具使用; 掌握 Skills 原理及场景化设计

RAG: 掌握文档切分, Embedding, 向量存储, 向量检索, 召回后筛选与补全, 具备 RAG 优化能力 **Agent:** 掌握 Agent 开发原理, 掌握基于 LangGraph 的 ReAct Agent, 工具编排与 workflow 设计

后端: 掌握 Python 后端开发, 熟悉 FastAPI 主流框架, 能够进行 RESTful API 设计与后端业务开发

工程化能力: 熟悉 Git, Docker, Nginx, Redis, 具备 AI 应用工程化落地能力

前端: 掌握 HTML / CSS / JavaScript, 熟悉 Vue 框架, 能够完成基础页面开发, 接口对接及前后端联调