

- 文档处理：采用层次化节点解析器，按 1000/250 两级切分文档，只对叶节点构建向量索引和 BM25 索引，解决长短文档分数不可比问题
- 混合检索：实现 BM25 关键词检索与向量语义检索并行执行，差异化聚合后通过 RRF

算法融合，兼顾召回率与精确率

- 查询扩展：原始查询权重 0.5，LLM 改写 3 个查询平分剩余 0.5 权重，扩大检索覆盖面
- 检索优化：集成 BGE Reranker 对检索结果重排序，过滤低相关度文档，提升最终结果质量
- 存储设计：MySQL 存储父文档与子文档，ChromaDB 存储向量索引，支持文档增量更新和 BM25 索引热重建
- 问题解决：解决了 AutoMergingRetriever 父节点丢失、ChromaDB 数据残留导致节点 ID 不匹配等问题

项目二：混合检索+加权融合 RAG 智能问答系统（2026 年 5 月-至今）

项目描述：构建了一个生产级 RAG 问答系统，支持文档智能解析、混合检索、加权融合和流式输出。系统采用层次化文档切分策略，实现父子文档关联存储与检索。创新性地实现了加权查询融合检索器，支持原始查询权重分配和双检索器加权 RRF 融合，有效提升了检索准确率

技术栈：Python、LlamaIndex、LangGraph、ChromaDB、Redis、PostgreSQL、通义千问、BGE

核心贡献：

- 文档处理层：使用层次化节点解析器将文档切分为 1000/250 两级节点，仅对叶节点构建向量索引和 BM25 索引，解决了长短文档分数不可比的问题
- 混合检索层：自研 WeightedQueryFusionRetriever，支持原始查询 0.5 权重、LLM 改写查询平分剩余 0.5 权重，AutoMerging 检索器和 BM25 检索器分别以 0.6 和 0.4 权重进行 RRF 融合
- 存储架构：Redis 存储文档节点和索引元数据，ChromaDB 存储向量，PostgreSQL 存储会话检查点和长期记忆，实现了多会话隔离和用户偏好记忆
- 流程编排：基于 LangGraph 构建了记忆加载→摘要压缩→检索→评估→生成的完整工作流，支持检索质量评估和自动重试机制

◆教育经历

2023.06-2027.06 河北工程大学 本科

◆自我评价

具备扎实的大模型应用开发能力，在 RAG 和 Agent 方向有完整项目落地经验。RAG 侧，独立实现了层次化文档切分、加权查询融合检索、双重权重 RRF 融合、检索质量评估与自动重试等核心模块，解决了长短文档分数不可比、检索结果碎片化等问题。Agent 侧，基于 LangGraph 实现了 Plan-Execute 模式，包括结构化输出规划、依赖解析并行分发、动态重规划、人机交互中断恢复、长期记忆自动提取等核心能力。