


胡选杰

☎ 13276387009 | ✉ 755877147@qq.com

📅 24岁 🧑 男 🎯 AI应用开发工程师 🏆 共青团员



教育背景

中央民族大学

计算机科学与技术 (硕士)

2025.09 - 2028.06

烟台大学

计算机科学与技术专业 (本科)

2020.09 - 2025.06

专业技能

Agent 工程: 熟悉任务路由、工具调用、多轮上下文管理与执行链路设计; 了解 Claude Code、Agent Harness、MCP、A2A 及 ReAct/Plan-Execute 等编排模式。

LangGraph: 熟悉工作流编排, 能够完成多节点路由、状态传递、记忆管理与 Agent 工作流设计。

RAG: 熟悉检索增强生成流程, 具备文档解析、Chunk 切分、召回链路设计、检索优化等经验。

大模型原理: 了解 Transformer 基本架构、注意力机制、Prompt、上下文窗口与大模型推理流程。

Python 技术栈: 熟悉 Python、FastAPI、LangChain、FAISS、Linux、Git 等 AI 应用开发与服务化工具。

语言能力: 通过 CET-6, 有独立阅读理解英文文献, 英文文档能力。

项目经历

Coding Agent — 终端 AI 编程助手

大模型应用开发

2026.01 - 至今

技术栈: Python, MCP, ReAct, Skill, Multi-Agent

项目介绍: 轻量级终端 Coding Agent, 基于 ReAct 与 Plan Mode 双模式驱动 LLM 自主完成编程任务。交互、引擎、工具、记忆、安全五层分层架构, 支持 Anthropic、OpenAI 双协议、MCP 工具扩展、Skill 技能包、跨会话记忆、多 Agent 并行协作。

技术亮点:

- MCP 工具延迟加载**: MCP 工具注册时只传名称不传完整 schema, LLM 按需发现后再加载完整定义, **百级工具场景下工具描述 Token 占用减少85%**, 避免上下文窗口被工具定义挤占
- 两层上下文压缩**: 设计两层渐进式上下文压缩策略, 自动对齐 Function Calling 的调用配对约束, **支持数小时连续编程会话不丢失上下文**
- 五层权限拦截**: 设计覆盖命令拦截、路径沙箱、规则引擎、权限模式、人工确认的五层权限拦截模型, **任一层拒绝即终止操作, 支持 Agent 全自动模式安全执行**
- 自动记忆提取**: 每轮对话结束后异步调 LLM 回顾对话内容, 自动将用户偏好、纠正反馈、项目知识、参考信息四类记忆分类持久化到独立文件, **跨会话知识持续累积, 同类错误纠正一次后自动规避, 新会话自动继承项目上下文无需重复交代**
- 多 Agent 协作**: 将复杂任务拆分给多个 Agent 并行处理, 基于 Git Worktree 实现文件级隔离避免编辑冲突, Coordinator Agent 只负责任务拆分与结果汇总不参与编码, **突破单 Agent 上下文窗口瓶颈, 大型任务处理效率成倍提升**

智能Oncall Agent系统

大模型应用开发

2026.01 - 至今

项目介绍: Auto OnCall 系统通过 AI Agent 解决团队真实痛点, 整合 知识库、对话、运维 三大核心能力, 实现 问题自动应答 和 故障智能排查 的一体化服务。致力于降低团队 OnCall 的人力成本, 提升团队效率。

技术栈: LangChain、LangGraph、RAG、ReAct、Plan-Executor、Multi-Agent、MCP

项目亮点:

- 对话上下文窗口超限导致 LLM 调用失败。设计对话摘要机制, 保留最近 50 轮完整对话和历史摘要, 在保证上下文连贯性的前提下, 上下文 Token 使用率降低 60%
- 多用户并发对话存在上下文混淆问题。采用用户 ID 作为会话隔离标识, 为每个会话分配独立的对话记忆实例, 实现万级并发用户的对话隔离和状态管理
- AI 响应速度慢影响用户体验。通过流式输出机制实现 LLM 响应的逐字推送, 解决大模型响应延迟问题, 前端呈现实时对话效果。
- 负责 AIOps 功能开发。解决了传统运维需要人工排障的低效问题, 将运维响应时间从小时级降低到分钟级。

荣誉证书

- 烟台大学连续三年优秀学生奖学金、中央民族大学学业奖学金
- 全国大学生数学建模竞赛山东省一、全国大学生数学竞赛山东省一