

施佳俊

电话：15531653317 邮箱：1587862672@qq.com 应聘岗位：大模型应用开发

教育背景

燕山大学（保研）| 硕士 | 计算机科学与技术 | 2024.09 -- 至今

研究方向：具身智能、大模型应用 荣誉奖项：中国机器人及人工智能大赛国家级二等奖、校一等奖学金 2 次

山西财经大学 | 本科 | 计算机科学与技术 | 2020.09 -- 2024.06

荣誉奖项：计算机设计大赛国家级二等奖、校一等奖学金 4 次

技术技能

大模型与 Agent：LangGraph、多 Agent 协作编排、Function Calling、ReAct、Reflection、Prompt Engineering

RAG 检索：RAG、HyDE、Query Rewrite / Expansion、BM25、向量检索、Cross-Encoder Rerank、Milvus

工程能力：FastAPI、Docker、Redis、SSE 流式输出、Git

编程语言：Python

项目经历

实验室横向：面向具身智能任务辅助的 DeepResearch 多 Agent 系统

多 Agent 应用开发 / 工作流编排

项目描述：面向具身智能场景下的环境理解、任务拆解、知识检索与决策支持需求，设计并实现多 Agent 深度研究系统。系统融合多 Agent 协作编排、混合检索、长短期记忆、工具调用与评审反馈机制，支持从任务意图解析、证据检索、数据分析到报告生成与结果修订的完整闭环。

核心技术与方法：

- 多 Agent 工作流设计：**设计规划、调研、分析、可视化、撰写、评审的 6 Agent 协作流程，基于 LangGraph 状态图编排 DAG 调度；在 Planner 阶段生成 3-5 个可验证假设，并通过 Reviewer 节点对引用完整性、逻辑一致性、信息时效性和内容缺失进行评审，根据问题类型路由至补充检索或内容修订。
- Tools 集成与优化：**集成 WebSearch、RAG、Text2SQL、Code Interpreter 等工具；复用前期 RAG 项目沉淀的 Milvus + BM25 + Rerank 混合检索链路，将本地知识库检索封装为 Researcher Agent 可调工具；通过 Function Calling 统一封装工具名称、参数 Schema、返回格式和异常处理逻辑。
- 记忆层设计：**设计 ResearchState 全局共享状态，维护 query、outline、facts、data_points、draft、feedback、messages、citations 等字段；结合短期记忆、长期记忆和 Checkpoint 机制，支持跨 Agent 上下文继承、中断恢复和跨会话知识复用。
- 工程侧优化：**基于 FastAPI + Docker 完成服务封装与容器化部署；通过 Redis 管理任务状态和中间结果缓存；引入 SSE 流式输出，使用户可实时查看任务规划、检索、分析、撰写和评审阶段状态。

项目成果：

- 多 Agent 研究闭环落地：**构建从任务规划、资料检索、证据分析、报告撰写到评审修订的多 Agent 闭环，降低单 Agent 职责耦合问题。
- 报告可追溯性增强：**通过证据抽取、引用绑定和 Reviewer 评审机制，使输出内容引用覆盖率稳定在 85%+。
- 迭代修订效率提升：**通过评审反馈路由与反思修正机制，将任务平均迭代轮次控制在 2 轮以内。
- 长任务交互体验优化：**基于 SSE 流式输出展示任务执行阶段状态，首字响应时间控制在 500ms 以内。
- 任务分析效率提升：**相比人工串行整理资料，任务分析耗时缩短 60%+。

实验室横向：面向具身智能任务规划的多模态知识增强问答系统

RAG 应用开发 / 知识库构建 / 检索优化

项目描述：面向具身智能任务规划与环境认知场景，构建多模态 RAG 知识增强问答系统，将设备操作手册、环境规则文档、任务 SOP、课件 PPT、视频字幕等多源资料统一解析入库，为复杂任务指令理解、环境知识检索和决策辅助提供支撑。

核心技术与方法：

- 离线解析及知识库构建：**结合自然段落、标题层级、页码、章节编号和任务步骤边界进行结构化切分；针对扫描版 PDF 和图文混排资料，采用 PaddleOCR 进行 OCR 识别和段落重组，保留来源、页码、章节、幻灯片编号等元信息。
- Query 模块优化：**利用规则、BERT 分类器和 Prompt Engineering 识别设备操作、任务流程、环境规则、异常处理等查询意图；通过 Query Rewrite / Expansion 对口语化、错别字、简称和模糊问题进行纠错与同义扩展；引入 HyDE 丰富复杂任务查询的语义表达。
- 检索召回模块：**采用 BM25 + 向量检索混合召回，针对具身智能场景短查询多的特点，短查询优先关键词匹配，长查询结合语义检索；基于具身智能任务文档和问答样本优化 Embedding 表征；使用 Cross-Encoder Rerank 对候选片段二次排序，提高高相关内容前置能力。
- 生成阶段优化：**设计多轮对话 Context Injection 和实体补全机制，保证连续追问语义连贯；统一检索 PDF、PPT、视频字幕和实验记录等多模态内容；在答案中标注文档、页码、章节或视频时间戳，提升结果可解释性。

项目成果：

- 检索准确率提升：**Recall@10 从 53% 提升至 89%，Top5 准确召回率从 67% 提升至 86%，MRR 从 0.51 提升至 0.71。
- 多轮问答能力增强：**代词解析与上下文保持使多轮提问准确率提升 25%。
- 多模态资料统一入库：**将实验 SOP、设备操作手册、环境规则、PPT、视频字幕和扫描文档统一解析入库，提升多模态资料可检索性。
- 答案可解释性提升：**设计答案引用机制，将关键结论定位到文档、页码、章节、PPT 页码或视频时间戳级别，提升结果可解释性。
- 支撑 Agent 决策辅助：**将 RAG 能力接入上层 Agent 任务理解与决策辅助流程，为具身智能任务规划提供知识增强支撑。