

李鑫

19862255726 | znnn2004@163.com

中共党员



教育经历

推免至天津大学 985 211 双一流

2026年09月 - 2029年06月

电子信息 硕士 软件学院 全日制

中国石油大学(华东) 211 双一流

2022年09月 - 2026年06月

软件工程 本科 全日制

- GPA: 4.09 专业排名: 6/189 (3.17%)
- 英语能力: CET-6 (583)
- 荣誉奖项: 综合优秀奖学金、优秀学生、优秀学生干部、优秀毕业生

实习经历

胜利油田数智化管理服务中心

2026年02月 - 至今

全栈开发实习生

项目背景

传统单智能体医疗问答方案在响应速度、复杂问题拆解、多轮上下文把握及持久记忆上较为薄弱，面对多症状、跨维度咨询时输出准确性与一致性易波动，难以满足临床与公众场景对高效、可信、可控的要求。

解决方案

- 采用Skills-Agent 双层架构：底层构建7个原子化 Skills，覆盖知识检索、风险评估、症状分析、生活方式建议、ICD-10 编码、临床指南检索与深度研究等能力，供上层 Agent 灵活调用；上层设计3类专业 Agent，包括健康咨询 Agent、症状诊断 Agent 与医学研究 Agent，可根据任务需求自主选择合适的 Skill，且 Skills 与 Agent 保持完全解耦。
- 引入 Agent Loop 执行机制：基于 ReAct 框架实现 Think-Act-Observe 循环，由 LLM 自主判断是否调用工具、调用何种工具，并根据观察结果继续推理。系统设置最多2次工具调用的硬性限制，避免无效或过度调用，使单 Agent 平均响应时间控制在15秒以内。
- 构建 Agent Swarm 协作系统：通过智能路由模块判断问题复杂度，实现约70% 常规问题走单 Agent 快速通道、约30% 复杂问题进入 Swarm 协作模式。对于复杂医疗咨询，系统可自动拆解子任务并分配给多个 Agent 并行处理，Agent 之间通过共享上下文间接同步任务状态与执行结果，从而提升复杂问题的分析完整性与响应效率。
- 设计双层记忆机制：短期记忆负责管理会话级对话历史，采用单例模式确保所有 Agent 共享同一会话上下文，并集成熵管理器对消息进行自动去重与压缩，压缩率约35%，同时加载最近5轮对话以保持多轮交互连贯性；长期记忆则基于 Mem0 云服务，将会话总结向量化存储，支持跨会话的相似案例检索与长期上下文复用。
- 建立 Harness Engineering 约束系统：通过 YAML 文件显式定义各 Agent 的能力边界，并在运行时进行自动验证；同时实现输出自动修复机制，例如在缺少医疗免责声明时自动补充说明，在检测到高危症状时自动添加就医警告，从而增强系统输出的安全性、合规性与可控性。

项目成果

- 系统性能：智能路由准确率从88%提升至95%，知识库检索准确率87%，单Agent响应时间5-15秒，Swarm响应时间20-30秒，多轮对话上下文理解准确率从60%提升至92%；
- 回答质量：医学专业人员三维度盲评打分，系统回答质量4.5分 vs doubao-seed-2.0-pro 3.9分；

项目经历

教学实训智能辅助系统 | 毕业设计项目

2025年12月 - 至今

项目背景

针对高校实训教学中备课出题成本高、个性化辅导不足、反馈滞后，以及通用大模型存在知识幻觉、结果不稳定等问题，本项目融合大模型、RAG 与 Agent 技术，构建面向实训课程的教学智能辅助系统。

解决方案

- RAG 知识问答链路：构建课程级知识库，将教材、讲义、课程大纲等文档进行清洗、切分和向量化，基于 ChromaDB + DashScope Embedding 实现语义检索，并融合 BM25 关键词检索与 Rerank 重排序，提升课程知识问答的召回质量；针对多轮追问引入 Query Rewrite，将上下文依赖问题改写为独立检索 query，减少检索漂移。
- LangGraph Agent 编排：将复杂教学任务建模为“意图识别 → 任务规划 → 工具调用 → 反思纠错 → 结果聚合”的状态机流程，支持知识问答、备课生成、练习生成、答案评分、个性化推荐等多类意图；通过反思节点检查 JSON 格式、知识点覆盖、答案 grounded、时间预算等维度，失败时自动回到规划节点重试，提升复杂任务稳定性。
- MCP Tool + Agent Skills 双层架构：底层通过 MCP Server 暴露 search_kb、generate_exercise、grade_answer、lesson_outline、get_mastery 等原子工具，上层用 Skills 封装备课、个性化练习、简答评分等高层工作流，使 Agent 能按任务动态组合工具，而不是把业务逻辑硬编码在 Prompt 中。
- 性能与稳定性工程：围绕 LLM 调用链路的高延迟、高成本与稳定性问题，基于 Redis 设计 Embedding、检索结果、LLM 响应三级缓存方案，有效减少重复推理开销，提升接口响应效率与服务稳定性。
- 评测与可观测性体系：搭建 RAGAS + LLM-as-Judge + Golden Set 的三层评测体系，覆盖 RAG 问答、Agent 任务、题目质量和简答评分一致性；接入 LangFuse Trace 记录 Agent 节点、工具调用、LLM 调用和缓存命中情况。

项目成果

- RAG 问答效果：在 QA 测试集全链路 RAGAS 加权均值 AR 0.904 / CP 0.902 / CR 0.983；同条件下相比纯向量 baseline，context_precision 从 0.793 → 0.902、context_recall 从 0.900 → 0.983，混合检索 + Rerank 显著改善检索质量。
- Agent 编排效果：Agent 任务端到端评测，无反思 baseline 任务成功率 73.7%，引入反思节点后提升至 90.3%，主要恢复 JSON 格式与字段缺失等可纠错失败；端到端意图识别 92.1% / Skill 命中 97.4% / LLM-as-Judge 4.51/5。
- 性能与成本：缓存累计命中率达到约 42%；冷→热 QA 平均延迟 -68.5%、P50 24.4s → 2.5s，LLM Token 调用成本降低约 33%。

科研经历

Integrating Global and Local Features for Multisource Remote Sensing Image Classification with 2D Selective Scan Fusion (IJRS 2026)

以共同作者身份发表 SCI 论文(International Journal of Remote Sensing):设计 CNN-Mamba 融合的深度神经网络并完成全部对比与消融实验,精度优于 8 种主流方法。