

基本信息

姓名：雍帅旗 年龄：22岁
性别：男 籍贯：河南
电话：15639336997 邮箱：2282240914@qq.com
求职岗位：AI 应用开发



教育背景

河南理工大学 (2027年毕业)

计算机科学与技术

主修课程：数据结构、计算机组成原理、计算机网络、计算机操作系统、Java、JavaWeb、数据库原理、Spring Boot
在校荣誉：英语四级 (CET-4)

技能特长

大模型应用开发

- 熟练应用 SpringAI、LangChain、LangGraph 等主流大模型开发框架。
- 熟悉 Transformer 的核心架构原理及核心机制，了解其与 RNN、LSTM/GRU 的区别。
- 熟悉 Prompt 工程：System Prompt 设计、Few-shot 示例、防幻觉约束、输出格式控制。
- 熟悉 RAG (检索增强生成) 全链路技术，能基于 Milvus / Chroma 等向量数据库构建企业级知识库。
- 熟悉 MCP、Tool、Skill 的区别和各自的优缺点；熟悉 Agent Skills 的封装与调用。
- 熟练使用 Coze 等一站式 AI 智能体开发平台，熟悉复杂工作流 (Workflow) 的可视化设计与编排。
- 熟悉多模态模型集成 (图像 / 视频 / 文本)，具备结合图像与文本信息进行 OCR 提取、内容理解及回答生成的经验

Java后端开发

- 熟练使用Java并发编程，对Java的各种锁机制、线程池机制、ThreadLocal等都有深入了解，并在项目中熟练使用。
- 熟悉 JVM，对GC算法、垃圾回收器、类加载器、JVM组成都有深入理解。
- 熟悉 MySQL，对SQL优化、索引、事务、日志、主从同步、分库分表等有深入研究。
- 熟悉 Redis，了解缓存穿透、缓存击穿、缓存雪崩、数据持久化、分布式锁等。
- 熟练使用Spring、SpringMVC、SpringBoot、MyBatis等核心框架，可以根据需求快速搭建项目。
- 熟悉 SpringCloud Alibaba，了解服务注册与发现、负载均衡、服务雪崩、服务监控等。
- 熟悉 消息中间件RocketMQ的消息丢失、消息幂等、延迟队列、异步消费技术的原理和使用。
- 熟练运用Claude Code、Cursor、Trae等AI编程工具，深度融入开发工作流，实现开发效率倍增。

实习经历

2025-12 ~ 2026-05

河南省守仁实业有限公司

Agent开发工程师

项目经验

企知通·智能问答系统

Agent开发工程师

2025-12- 2026-05

项目描述：针对企业内部知识分散、传统检索效率低、通用大模型存在幻觉等痛点，设计并研发可复用的企业级 RAG 智能问答平台。系统支持多格式文档解析、向量+关键词混合召回、Rerank 精排及片段级引用溯源，服务于内部制度、产品手册、技术资料等核心知识场景，提升企业内部知识检索与问题解答效率。

技术选型：SpringBoot、FastAPI、LangChain、RAG、Milvus、Redis、MySQL、LLM

核心职责：

- 负责企业知识库问答平台设计与开发，完成文档上传、解析、切分、向量化、检索、重排、生成的完整 RAG 链路建设
- 针对 PDF、Word、Markdown 等文档实现统一解析与清洗流程，通过标题分段、语义分块、重叠窗口等策略优化知识切片质量
- 设计混合召回机制，结合向量检索与关键词检索提升召回覆盖率，并通过 Rerank 精优优化最终上下文质量
- 实现答案引用溯源能力，返回命中文档片段及来源信息，提升回答可信度并降低模型幻觉风险

- 引入会话上下文管理机制，支持多轮问答与历史语义延续，提升复杂问题连续交互体验
 - 针对召回 Topk、分块大小、Prompt 模板进行调优，提升知识问答准确率与稳定性
- 成果：
- **通用 RAG 知识库能力抽象**：将知识问答能力从教育场景中抽象为通用企业知识库解决方案，支持制度文档、产品手册、技术资料等多类型知识接入，具备跨场景复用能力
 - **混合召回与精排优化**：结合向量检索与关键词检索构建多路召回机制，并通过 Rerank 精优优化上下文质量，相比单一向量检索方案，召回准确率提升约 20%+
 - **答案可信度与可解释性增强**：实现引用溯源机制，返回命中文档片段与来源信息，显著降低“无依据生成”问题，用户对答案可信度提升
 - **知识分块策略优化**：基于语义分段、标题结构与重叠窗口设计分块策略，提升知识切片质量与上下文相关性，减少信息缺失与上下文断裂问题
 - **多轮对话体验优化**：引入上下文记忆与历史语义融合机制，支持复杂问题连续交互，提升用户问答连续性与交互体验

多 Agent 智能体平台 · 智能数据分析助手

个人项目 · 全栈开发

2026-01- 2026-04

项目地址：<https://gitee.com/xiaoyongflag/chat-bot>

技术栈：Python · LangChain · 通义千问 (Qwen) · Streamlit · RAG · Agent · Vision

项目描述：基于 LangChain 与 Qwen 大模型，从零构建集 RAG 知识库问答、数据分析 Agent、多模态 Vision 识别、多轮对话 于一体的多模态企业智能助手平台，实现类 ChatGPT 的统一交互体验。

● **架构设计**：基于 LangChain 设计四层架构（输入层 → 意图层 → 能力层 → 响应层），使用 Pydantic 定义结构化数据模型，实现类型安全与可扩展的业务抽象。

● **智能意图识别**：构建两阶段意图识别 Pipeline，通过 Few-shot Prompt 强制输出结构化 JSON；低置信度请求自动兜底。

● **RAG 知识库系统**：设计完整文档处理链路：PDF 解析 → 智能分块（800 字符 / 120 重叠）→ 向量化 → 语义检索 + 引用溯源；支持多文档并行处理与来源页码标注。

● **数据分析 Agent**：实现 DataFrame 元信息提取 → LLM 生成代码 → 沙箱执行 → 结果可视化闭环；支持动态图表生成，提升数据分析效率。

● **多模态 Vision 能力**：集成通义千问 VL 视觉大模型，实现图片内容提取、发票识别、截图分析，关键字段提取准确率 95%+。

● **可控记忆管理**：设计会话隔离机制，实现最近 10 轮对话窗口裁剪，降低 Token 消耗。

● **交互界面开发**：基于 Streamlit 构建类 ChatGPT 交互界面，集成文件上传、意图徽章可视化；单文件部署

自我评价

- 熟练使用 Cursor、Claude Code、等热门的 AI 工具，用 AI 来提升开发效率以及编写一些前端代码
- 计算机科班出身，具备扎实的代码能力，拥有多个完整项目开发实战经历，能快速理解业务需求并高效投入项目开发
- 拥有较强的文章书写能力，制作学习思维导图，业务分析能力和解决能力强
- 平时学习喜欢钻研新的技术，学习编程思路并落实到实际项目中