

魏正沙

年龄: 28 岁
性别: 男
民族: 汉

现居: 重庆市两江新区
电话: 15690363661
邮箱: 865461908@qq.com



教育背景

2024.09-至今	重庆大学	电子信息/硕士（在读）
2020.09-2022.06	唐山学院	计算机科学与技术/本科

项目经历

金融智能客服多 Agent 系统

项目背景: 面向金融场景的企业级智能客服系统, 采用多 Agent 架构替代传统单体客服机器人。

核心职责:

- 设计并实现基于 Supervisor 编排模式的多 Agent 协作架构, 包含意图路由、知识检索(RAG)、工单处理、合规审查 4 个专业 Agent。
- 构建 三层记忆系统 (工作记忆 + Redis 短期记忆 + 向量库长期记忆), 解决多轮对话上下文丢失问题。
- 实现完整 RAG 流程 (Query 改写 → 向量检索 → 重排序 → 上下文注入), 知识库检索准确率达 92%。
- 基于 MCP 工具协议 实现标准化工具调用层, 统一对接订单系统、工单系统、风控接口。
- 集成 OpenTelemetry 全链路追踪, 实现 Agent 调用链路可视化和 Token 消耗监控。

技术栈: Python / LangGraph / FastAPI / Redis / FAISS / OpenTelemetry / Docker

项目成果:

- 首问解决率(FCR)从 65%提升至 82%, 客户满意度 CSAT 从 4.3 提升至 4.7。
- Token 消耗通过分层记忆+缓存策略降低 40%。合规风险事件减少 95%, 实现金融合规自动化审查。

金融保险知识库 RAG 系统

项目背景: 面向金融业务的 RAG 知识库建设, 为金融公司员工提供基于本地知识库的即时问答服务。

核心职责:

- 离线解析及知识库构建: 设计多模态解析 Pipeline, 利用 OCR 与智能分块策略 (结合自然段落与层级标签) 处理复杂文档, 最大程度保留表格结构与上下文语义, 解决信息割裂问题。
- Query 模块优化: 构建意图识别与 Query 重写/扩写机制, 引入 HyDE (假设性文档嵌入) 策略生成丰富查询语义, 有效纠正口语化表达并显著提升长尾问题的检索召回率。
- 检索召回模块: 实施 BM25+向量混合检索与 Embedding 领域微调, 配合 Cross-Encoder 重排策略进行二次精排, 经测试集验证, P@3 指标提升约 30%, MRR/NDCG 提升 20%+。
- 生成阶段优化: 实现多轮对话上下文管理与多模态内容整合, 开发答案引用溯源机制 (自动标注文档页码/视频时间戳), 在保障回答准确性的同时大幅提升结果的可解释性与用户信任度。

技术栈: RAG / OCR / FastAPI / Router / Cross-Encoder/Milvus/Sentence-Transformers

项目成果:

- 混合检索+微调+重排策略在内部测试中, Top5 准确召回率从 65%提升至 88%, MRR 从 0.50 提高至 0.72。
- 代词解析与上下文保持使多轮提问准确率提高 25%+; 用户在后续追问时能得到连贯、上下文一致的回答。

个人能力

专业技能: 熟练掌握 Python 开发语言。熟悉 RAG、Agent、Function Calling、LangGraph、Multi-Agent、Memory、Skill、Harness、Prompt Engineering、MCP 等大模型应用开发技术。

科研经历: SCI 论文在投一篇; 发明专利授权一项; 参与了与塞力斯汽车公司联合开展的“增程式电动汽车场景识别与智能增程控制系统开发”项目。