

姓名：牛锐搏

电子邮箱：17843151760@163.com

年龄：21

联系电话：17843151760

教育背景

长春工业大学 - 计算机科学与技术-省重点

2023.09 - 2027.06

成绩优异，GPA 3.37/4.0（前15%） 奖项：二等奖学金，三等奖学金

主修课程：人工智能导论，软件工程，算法设计，计算机操作系统，数据库原理，数据结构，全栈web开发

奖项：美国数学建模竞赛（美赛）团队二等奖（H 奖），蓝桥杯省二等奖

证书：2026.06 阿里达摩院 人工智能训练师（高级） 2026.6 LinkedIn Learning 生成式 AI 入门认证

项目名称：跨境电商 AI 实时语音智能客服平台

项目概述：针对大促及跨境场景，构建高并发、低延迟的 AI 语音系统，涵盖导购与售后业务。通过优化 RAG 检索、推理链路及 RTC 弱网策略，解决复杂电商环境下响应慢、专有名词识别率低等痛点。

1. 提示词工程与模型精调 (Prompt & Fine-tuning)

- 自动化评测体系**：基于 Prompt Pilot 搭建电商专属评测集，通过自动化评分实现版本快速迭代，确保回复符合品牌语调与业务逻辑。
- 负样本重构算法**：针对售前咨询中的“理解偏差”样本，利用智能优化算法重构提示词，并沉淀高质量对话数据，为后续模型精调 (Fine-tuning) 提供核心素材。

2. RAG 知识库与检索链路优化 (Retrieval Optimization)

- 混合检索与量化存储**：采用自定义标识符切片处理海量 ViKing DB 知识库，应用 HNSW_HYBRID 混合检索与 Int8 量化，配合 Metadata 标签过滤，实现存储空间降低 75%。
- 精准命中与提速**：引入 base-rerank 轻量化重排模型，动态平衡 dense_weight，显著提升品牌、型号等电商专有名词的命中率，检索速度提升 4 倍。

3. 推理链路性能压榨 (Inference Performance)

- 首字延迟 (TTFT) 优化**：通过固定 RAG 片段排序、合并 System Prompt 等策略，深度触发 Prefix Caching 与 KV Cache，将复杂 RAG 场景下的 TTFT 从 15s 压缩至 2s 内。
- 成本与弹性控制**：构建 Max Token 分级控制模型，根据电商场景动态配置推理比例，提升 Token 利用率；针对大促流量波峰进行资源池优先级调优。

4. RTC 语音链路与情感交互 (Real-time Communication)

- 情感化反馈**：基于 ASR 实时捕获用户在大促催货或投诉时的情绪波动，配合 TTS 声音复刻技术，实现更具同理心的语音交互，提升用户满意度。
- 弱网抗性优化**：利用 FEC（前向纠错）与自适应 Jitter Buffer 协同，实现 50% 高丢包环境下语音通话无感知恢复，确保极端网络下的交互连续性。

5. 工程效能与集成环境 (Engineering Efficiency)

- **可视化评测环境**：利用 Swagger UI 抽象核心业务逻辑，配合 Ngrok 公网映射解决 RTC 语音回调调试难题。
- **热更新机制**：优化 Python 服务 reload 策略，将开发重启耗时从 10s 降低至 2s，大幅缩短团队在处理紧急业务需求时的迭代周期。

项目名称：基于 MCP 与 LangGraph 子图架构的分布式电商 Agent 系统

项目描述：

针对大型电商平台多业务线 AI 能力孤岛与复杂决策链路难以维护的痛点，主导研发了一套分层解耦的分布式多 Agent 操作系统。底层基于 MCP (Model Context Protocol) 协议实现基础设施标准化，上层利用 LangGraph 父子图 (Parent-SubGraph) 架构实现了售前导购、售后风控、营销创作、财务账单四大职能的深度隔离与协同。系统支撑了跨场景“用户画像实时同步”与“多模态知识精准唤醒”，单 Agent 迭代效率提升 70%。

核心技术贡献：

1. 协议驱动的架构解耦：基于 MCP 的分布式服务集群

- **服务标准化 (MCP Server)**：独立研发了 4 个核心 MCP Server (LLM 路由网关、RAG-Anything 多模态检索、跨域记忆管理、财务 SQL 工具)，将售前库存、售后 CRM、图片/报表解析及账单统计抽象为统一的 `Tools` 与 `Resources` 原语。
- **RAG-Anything MCP 服务化**：将 RAG-Anything 开源架构封装为标准的 MCP 协议组件，向外暴露 `parse_multimodal_doc` (多模态解析工具) 和 `hybrid_graph_search` (向量-图谱融合检索工具)，供上层四大子图 Agent 异步调用。
- **即插即用与热重载**：通过 MCP 标准协议实现业务逻辑与工具链的彻底解耦，系统扩展性提升 200%；中心化 Prompt 模板库支持大促期间营销话术与账单逻辑的**热重载 (Hot-Reload)**，业务策略秒级生效。

2. 工作流中枢：基于 LangGraph 的父子图协同编排

- **父子图架构 (SubGraph Layering)**：设计“中央路由器 + 四大职能子图”模式。将售前、售后、营销、账单封装为独立的 **StateGraph 子图**。子图内部逻辑高度内聚（如营销子图包含“素材生成 $\rightarrow$ 审美评估 $\rightarrow$ 反思修正”循环），主图仅负责全局上下文调度。
- **智能意图路由 (Supervisor)**：主图 Supervisor 节点通过调用 MCP LLM 网关解析用户意图，实现跨子图的状态流转。例如：根据账单子图反馈的消费等级，自动触发营销子图通过 MCP 调用生图工具，生成专属大额折扣券素材。
- **状态持久化与人机协同**：利用 PostgreSQL Checkpointer 实现 Graph 级状态持久化，支持 Human-in-the-loop (人工干预) 确认高价值账单或售后决策，确保业务合规与任务容灾。

3. 数据资产沉淀：跨域双层记忆与 RAG-Anything 多模态感知

- **跨域认知同步 (Shared Context)**：构建跨项目记忆引擎。对话层按 Session 隔离，**画像层（如：尺码偏好、过敏史、账单等级）**跨子图共享，实现“售前导购提取偏好，售后 Agent 自动感知”的无缝购物体验。
- **RAG-Anything 极致多模态优化**：利用 RAG-Anything 的多模态实体提取能力，攻克电商场景下详情图（尺码表、版型图）、促销海报、财务 PDF 报表中**复杂表格与视觉信息的结构化提取瓶颈**。
- **向量-图谱融合检索 (Vector-Graph Fusion)**：基于 Viking DB 实现租户级物理隔离，通过引入 RAG-Anything 的双图导航 (Dual-Graph) 检索算法并配合 **Cross-Encoder 重排序**，解决传统 RAG 破坏非结构化图表上下文的痛点，商品参数与活动规则命中率达 91%。

4. 极致性能与工程化：TTFT 压榨与可观测性

- **交互性能突破**：深度集成 SSE 流式输出与 `astream_events` 。通过监听子图内部 `on_chat_model_stream` 事件实现首字实时推送，将语音导购的**首字延迟（TTFT）降低 60%**。
- **模型路由降本**：构建动态路由网关，根据任务复杂度自动分发至不同规格模型（如：账单统计用 Pro，常规接待用 Lite），**降低 40% 推理成本**。
- **DevOps 闭环**：接入 LangSmith 实现父子图全链路 Trace 追踪，覆盖从“消费者提问”到“RAG-Anything 检索原语触发”的完整拓扑；设计 Mock 开关体系解耦外部接口，迭代周期缩短 50%。

项目名称：电商导购大模型系统微调

职责：负责本地LLaMA-Factory微调

技术架构

- **核心链路**：聊天数据清洗 -> 语义切分 -> 脱敏 -> SFT 微调 -> DPO 偏好对齐 -> 云端微调
- **技术栈**：Qwen2.5、豆包-1.5、LLaMA-Factory、Python、Elasticsearch、Cross-Encoder、火山引擎。

核心成果与技术实现

- **多模态数据提纯**：设计全流程数据清洗方案，自动过滤电商场景下的图片、语音及撤回等杂讯；利用 Embedding 余弦相似度 + 时间窗口 策略完成多轮对话切分，配合 **命名实体识别** 实现 98% 准确率的隐私脱敏。
- **“本地+云端”阶梯式微调**：
 - **验证期**：在本地 RTX 4090 环境下使用 QLoRA 对 Qwen2.5-3B 进行实验（rank=64, lr=2e-4），50分钟内完成模型验证。
 - **生产期**：迁移至火山引擎对 **豆包 1.5** 进行 LoRA 微调，风格一致性评分从 2.1 提升至 4.3，使 AI 回复更具导购亲和力与转化诱导性。
- **“职责分离”架构优化**：
 - **SFT (监督微调)**：负责学习销售话术风格与追单节奏，解决“怎么说”的问题。
 - **RAG (检索增强)**：构建 Embedding → 向量检索 → Rerank 三阶段 Pipeline，将商品价格、库存及促销策略等时效性知识接入向量库，知识命中率从 72% 提升至 89%，彻底解决模型在电商复杂规则下的幻觉问题。
- **DPO (直接偏好优化)**：基于 SFT 模型进行采样，由资深导购标注“更具转化潜力”的回复对（Chosen/Rejected），通过 DPO 训练解决“会说但说不好”的精排问题，进一步提升模型对客户下单欲望的激发能力。
- **全链路集成与评估**：
 - 接入 RTC 实时语音系统，通过微调优化 **System Prompt** 长度，显著降低首字延迟（TTFT），保障直播间/语音客服的流畅体验。
 - **业务收益**：经线上 A/B 测试验证，客户回复率提升 23%，有效会话时长提升 35%，咨询→试听/下单转化率达 18.2%（已逼近人工导购 19.7% 的水平）。

技能

1. 大语言模型 (LLM) 与微调评估

- **微调工程**：深入理解大模型微调全流程（数据清洗 $\rightarrow$ SFT $\rightarrow$ DPO），熟练掌握 LoRA / QLoRA 参数高效微调技术；具有 LLaMA-Factory 及火山引擎方舟平台实操经验；深刻理解 RLHF 与 DPO 的底层机制及业务适用场景。
- **评估体系**：熟练构建大模型多维评估体系，掌握 BLEU / ROUGE、语义相似度、A/B 盲评 及 Cohen's Kappa 一致性检验方法，具备量化模型迭代效果的能力。

2. 机器学习与深度学习底层原理

- **数学与统计基础**：了解监督学习与无监督学习的核心算法，掌握线性代数、概率论、梯度下降法
- **深度神经网络 (DNN)**：了解反向传播 (Backpropagation) 与自动微分机制；掌握 CNN (卷积神经网络) 及 RNN/LSTM 的演进逻辑。
- **模型优化与正则化**：了解过拟合处理方案 (Dropout、L1/L2 正则化、Batch/Layer)，具备对模型收敛曲线、损失函数波动进行深度诊断与调优的能力。

3. RAG 系统与提示词工程

- **RAG 全链路优化**：精通检索增强生成 (RAG) 全生命周期研发，熟练掌握高级文档切片、Embedding 向量化、HNSW 混合检索、Cross-Encoder Rerank 精排、Metadata 过滤及 Dense Weight 权重调优；具备 Int8 量化落地经验。
- **提示词与结构化**：精通 Prompt Engineering (提示词工程)，具备提示词版本管理、自动化评测与负样本迭代优化经验；熟练运用 Pydantic Schema / JSON Mode 确保 LLM 100% 结构化稳定输出。

4. AI Agent 与 workflow 编排 (含 MCP 生态)

- **workflow 编排**：熟练运用 LangGraph / LangChain 进行复杂 Agent 与 workflow 开发，深入掌握 SubGraph (子图) 架构、Checkpoint 状态持久化、SSE 流式输出及 LangSmith 全链路追踪调试。
- **MCP 协议生态**：深入理解 MCP (Model Context Protocol, 模型上下文协议) 架构；具备 MCP Server 开发经验 (基于 Python / TS SDK 开发自定义 Tools、Resources 和 Prompts)，能够将企业私有数据与本地工具链无缝注入 LLM 上下文。
- **AI 驱动开发 (Vibe Coding)**：全面拥抱 AI 研发新范式，熟练将自定义 MCP 服务集成至 Claude Code、Cline、Cursor 等主流 AI Coding 工具，具备极强的“人机协同”效率，能借助 Agent 快速完成原型构建、重构与复杂排障。

5. 高性能后端开发与架构

- **Python 高性能编程**：精通 FastAPI、Asyncio、Pydantic 生态，熟练掌握异步并发调度、同异步桥接、指数退避重试 (Exponential Backoff) 等生产级高性能后端编程范式。
- **基础设施与存储**：熟练使用 PostgreSQL 及主向量数据库 (Milvus / Qdrant / Pinecone 等)；熟悉 Docker 容器化部署、Linux 生产环境运维及 Git 规范化工作流。

6. 全栈能力与实时交互

- **RTC 实时交互**：熟悉 RTC 实时语音链路，具备 ASR (语音识别)、TTS (语音合成) 与声音复刻技术的对接与集成经验。
- **全栈开发 (Web & Front-end)**：熟练掌握 HTML5、CSS3、JavaScript/TypeScript；熟悉 React 及 Next.js 全栈开发框架，具备独立构建现代化全栈 Web 应用的能力。

- **前后端协同**：熟悉前端 SSE 流式解析（ReadableStream）及 Mock 体系设计，具备良好的前后端联调与协同效率。