



教育背景

西安理工大学 | 软件工程 | 硕士

2025.09 - 2028.07

西安理工大学 | 软件工程 | 学士

2021.09 - 2025.07

实习经历

陕西云创网络科技有限公司 | 大模型应用开发实习生

2025.08 - 2026.05

项目 1: 多模态大模型图生视频工程化与微调

- 【环境工程化】使用 Docker 固化 GPU+CUDA+Python 全栈依赖, 解决 40+包版本冲突, 环境搭建从 2 天压缩至 20 分钟。
- 【模型微调】在 24G 显存下采用 LoRA 对 Wan2.1 进行 3 轮超参调优, FVD 从 320 降至 215, 实现 5 秒 1080P 视频生成。
- 【训练工程】开发基于 tmux+nohup 的自动化训练脚本, 支持断点续训与日志推送, 中断率归零, 实验周期缩短 40%。
- 【项目成果】Docker 镜像实现环境问题归零; 微调模型 FVD 降低 105 点; 训练稳定性达 100%, 实验效率提升 40%。

项目 2: 智能语音客服 Agent 系统

- 【Agent 编排】基于 Dify 搭建可视化 Agent 工作流, 流程修改从 2 小时缩短至 10 分钟, 端到端延迟控制在 2.3 秒内。
- 【RAG 与多轮对话】引入上下文状态管理, 连续对话成功率从 58%提升至 87%; 语义分段+Prompt 优化, 召回准确率从 61%提升至 82%。
- 【系统联调】使用 ngrok 解决本地-云端-业务系统三方网络隔离, 2 天完成全链路联调, 交付可演示语音客服原型。
- 【项目成果】成功交付 AI 坐席系统, 支持完整客服流程与多轮对话, 提升场景覆盖能力。

项目 3: 企业级 AI 运维驱动的分布式财务 RPA 平台

- 【大模型交互】以 Coze/LLM 为自然语言触发入口, 结合二次对话校验, 将模型指令参数错误率从 15%降至 2%以下。
- 【RAG+匹配策略】设计“精确→编辑距离→向量”三级匹配, 清洗 1.1 万条历史凭证, 科目匹配准确率达 95%以上。
- 【AIOps 诊断】基于 LangGraph 实现“规划-执行-重规划”状态机, 通过 MCP 协议接入日志/监控/RPA, 故障定位从 2 小时缩至 5 分钟。
- 【项目成果】平台上线 4 个月自动处理 8000+张凭证, 日均效率较人工提升 30 倍, AIOps 故障定位时间缩短 115 分钟, 已服务 4 家子公司。

上海策良信息公司 | AI 大模型算法实习生

2024.12 - 2025.04

- 【调用适配】参与设计统一 LLM 调用层, 负责 OpenAI、Claude 及国产模型 (智谱、通义千问) API 的协议适配与参数转换代码实现。完成指数退避重试与熔断机制的编码与测试。模块上线后实测调用失败率低于 0.5%, 模型支持运行时热切换, 服务无需重启。
- 【多智能体】基于 LangChain 框架搭建 Multi-Agent 协作流程, 实现意图识别与子任务链式编排。参考开源方案实现 Agent 组件的按需实例化, 并完成中间推理结果的分步返回逻辑。优化后系统启动耗时在 3 秒以内, Agent 首包响应时间实测降低 40%。
- 【检索策略】负责 RAG 系统的检索模块开发, 集成 BM25 稀疏检索与 BGE 模型 Dense Embedding 双路召回策略, 并接入 Cross-Encoder 完成重排序。在 5000 篇技术文档的测试集上, Top-10 命中相关文档数从单路检索的 32 篇提升至 40 篇, 满足实时问答需求。
- 【实验优化】参与高频查询场景的性能分析, 协助设计 Redis 缓存层方案, 负责 Embedding 结果与用户查询的缓存读写逻辑实现。采用 LRU 淘汰策略, 实际运行时缓存命中率达到 85%, 端到端查询延迟压缩至 800 毫秒以内。

学到牛科技有限公司 | 嵌入式开发实习生

2023.07 - 2023.09

- 【系统开发】参与智慧农场环境监测系统开发项目, 负责温湿度数据采集、传输与云端存储功能模块的完整实现。基于 STM32 主控芯片与 DHT11 传感器完成环境数据实时采集, 设计低功耗采集策略满足农田场景长期部署需求。
- 【通信实现】采用 NB-IoT 无线通信模块结合 UDP 协议完成数据上报功能开发, 针对弱网环境设计断线重传与数据缓存机制。实现数据上报成功率稳定在 95%以上, 确保监测数据不因网络波动而丢失, 累计完成 2000 余条数据的上传测试。
- 【云端对接】配合完成云服务器端数据接收接口调试, 参与 SQLite 数据库表结构设计与存储逻辑实现。协助开发网页端数据可视化功能, 完成从硬件采集到前端展示的全链路联调, 保障系统各模块协同稳定运行。
- 【质量保障】参与代码审查与功能测试工作, 审查代码模块 8 个, 协助修复逻辑缺陷与性能问题 10 余处。通过单元测试与集成测试验证系统稳定性。

项目经历

Daisy's Garden 个人技术站 | 独立开发者

2026.01 - 至今

- 【全栈架构】基于 Nuxt3 搭建 SSR 全栈站点, Nitro Server 实现认证、评论、点赞等 8 个 RESTful 接口, 首屏加载时间控制在 1.2 秒内, 搜索引擎收录页面从 0 增长至 52 页, Lighthouse 性能评分 92 分。
- 【数据存储】使用 better-sqlite3 设计 6 张关系表, 支持注册登录、嵌套评论 (最大深度 3 层)、点赞及 24 小时去重浏览统计 (基于 IP+SessionId 复合去重), 数据库 P99 查询延迟≤5 毫秒, 日均页面访问量 247 次。
- 【部署运维】部署至阿里云 ECS (2 核 4G), 配置 Nginx 反向代理、PM2 进程守护及 Let's Encrypt HTTPS 自动续期 (每 60 天)。编写 PowerShell 一键部署脚本 (含依赖安装、构建、PM2 重启), 发布流程从手动 20 分钟压缩至单命令 3 分钟完成。

多角色虚拟智能体系统 | 负责人

2025.10 - 2026.01

- 【多角色 Agent 架构】基于 LangChain 搭建多角色 Agent 对话系统, 设计角色配置 Schema (含人格描述、对话风格、知识库边界)。独立维护 8 个并行角色实例, 20 轮对话后角色一致性保持 85%以上 (5 轮基线为 40%)。
- 【记忆检索】采用结构化摘要+关键词索引替代全量向量存储, 将用户画像与关键事件提取为结构化条目。在 200 轮对话场景下, 记忆检索延迟≤200 毫秒, 召回准确率 78% (基于 200 条标注样本评估), 实现轻量级长上下文记忆管理。
- 【语音集成】集成阿里云 ASR 与 TTS 服务, 选用 SSE 实现流式音频输出, 首 token 延迟从非流式的 4.2 秒降至 0.8 秒, 端到端响应速度提升 5 倍, 完成 32 轮完整语音对话流程测试 (含噪音环境识别成功率 91%), 显著提升实时交互体验。

专业技能

- 【编程语言】Python、TypeScript、Java、C++ | 全栈开发。
- 【AI 框架】LangChain、LangGraph、Dify、PyTorch、LoRA | RAG、Agent、AIOps。
- 【工程工具】Docker、FastAPI、WebSocket、Redis、Nginx、PM2 | Linux、SQLite/MySQL。
- 【证书荣誉】CET-6, 具备英文技术文档阅读能力; 研究生学业奖学金。