

王泽超 | Agent / 大模型应用研发实习生

电话: 15158269252 | 邮箱: wzc294621327@gmail.com | 出生年月: 2000. 10

教育背景

北京工业大学 软件工程 (硕士) 2024. 09--至今

浙江工业大学之江学院 计算机科学与技术 (本科) 2018. 09--2022. 06

荣誉与成果

- 奖学金: 北京工业大学研究生三等奖学金 (研一)。
- 发明专利: 《一种胸部 CT 肺炎病灶分割方法、系统、电子设备及存储介质》 (申请号: 2026105487420, 国家知识产权局已受理)。

专业技能

- 编程与数据: 熟悉 Python, 具备数据结构、脚本开发与工程化开发基础; 能够使用 Pandas、NumPy 进行数据处理与分析, 使用 Matplotlib 完成基础可视化。
- 大模型/RAG/Agent: 熟悉 RAG 基本流程与 Agent 工作流, 掌握 LangChain、LangGraph、ChromaDB、BM25、RRF、Cross-Encoder/LLM Rerank、Ragas、MCP 等组件。
- 后端系统: 能够使用 FastAPI 构建 RESTful API, 了解文件上传、接口调试、异步并发、数据库操作、SSE 流式返回与服务部署流程。
- 深度学习/CV: 熟悉 PyTorch 基础开发流程, 能够完成 Dataset/DataLoader 构建、模型训练、验证测试、模型保存与加载; 了解 CNN、Transformer、U-Net/nnU-Net 等视觉模型。
- 工具与英语: Linux、Docker、Git、Anaconda/Uv、Dify、MinIO、Apifox; CET-6, 能够阅读英文技术文档并进行功能开发。

工作与项目经验

神州医疗科技股份有限公司 AI 算法实习生 2025. 12--2026. 03

- 参与医学 NLP、影像识别、大模型及多模态相关功能研发, 支持医疗 AI 场景的需求理解、算法联调与功能落地。
- 参与心血管通路大模型项目搭建及多个内部项目开发, 负责部分功能开发、Bug 修复、流程调试与前后端联调。
- 基于 FastAPI 完成 Agent/大模型相关后端接口开发、数据库操作与工作流联调, 支持对话、工具调用等能力集成。
- 参与 CosyVoice3、PaddleOCR-VL 等模型服务部署与推理链路调试, 并通过异步并发改造提升服务吞吐与响应稳定性。

模块化企业知识库 RAG 检索与评估平台 独立设计与开发 2025. 12--2026. 03

技术栈: Python, LangChain, ChromaDB, BM25, Cross-Encoder, MCP Protocol, Streamlit, Ragas

- 面向企业私有知识库场景, 设计并实现模块化 RAG 框架, 覆盖文档摄取、语义分块、向量入库、混合检索、重排优化、评估观测与 MCP 服务暴露。
- 构建 BM25 + Dense Embedding 混合召回链路, 采用 RRF 融合排序, 并结合 Cross-Encoder/LLM Rerank 与失败回退策略, Top-10 命中率提升约 25%, MRR 提升约 20%。
- 搭建 Ingestion Pipeline, 完成 PDF 解析、Markdown 转换、Metadata 增强、Embedding 与 Upsert; 接入 Vision LLM, 将图片内容转为可检索文本。
- 实现 LLM/Embedding/Reranker/VectorStore 可插拔架构, 定义统一抽象接口, 通过配置文件支持 4+ LLM Provider 零代码切换。
- 集成 Query/Ingestion Trace、Ragas 与自定义指标, 围绕 Faithfulness、Answer Relevancy、Context Precision、Hit@K、MRR 等维度形成离线评测流程。

基于 LangGraph 的 ReAct 旅游智能体系统 独立设计与开发

技术栈: LangGraph, LangChain, PostgreSQL, ChromaDB, RAG, FastAPI, Selenium, Docker

- 基于 LangGraph 构建具备多轮对话、状态管理、工具调用、长短期记忆和 SSE 流式输出能力的旅行助手。
- 使用 FastAPI 搭建后端服务, 结合 JWT 实现无状态身份认证, 并通过 SSE 实现大模型回答的流式返回与实时中断。
- 设计短期 Session 与长期用户偏好分层记忆机制, 使用 PostgreSQL 存储会话状态, 使用 ChromaDB 存储长期偏好与检索内容。
- 封装饭店推荐、待办管理、PDF 自动生成、网页抓取等工具; 通过 Function Calling 与 MCP 协议接入高德 MCP 等第三方服务。
- 使用 Selenium 完成动态网页数据抓取, 处理验证码与 Cookie 复用问题, 为 Agent 提供实时外部信息获取能力。

胸部 CT 肺炎病灶涂鸦监督分割研究与模型改进 研究生科研项目 2024. 09--至今

技术栈: Python, PyTorch, Medical Image Segmentation, Transformer, Weakly Supervised Learning

- 面向胸部 CT 肺炎病灶分割任务, 使用 scribble 稀疏标注替代完整像素级 mask, 完成数据预处理、增强、训练验证测试与可视化。
- 基于 MaxViT-U-Net 与 query-guided Two-Way Transformer 框架进行模型改进, 引入 lesion-aware multi-scale fusion, 增强模型对小病灶、散在病灶和模糊边界的感知。
- 使用 Dice、IoU、Precision、Recall 等指标评估分割效果, 并围绕漏分、误分、小目标召回和边界质量进行误差分析; 相关论文投稿中, 发明专利已受理。