



马志宇

电话: 18333626898 | 邮箱: mzy20040729@163.com
求职意向: 大模型/NLP 算法工程师|微信: 18333626898
男 | 22岁 | 中共预备党员



教育背景

河北农业大学 计算机科学与技术专业

2022年9月-2026年6月

北京交通大学 计算机技术专业

2026年9月-2029年6月

- **专业成绩** : GPA 4.30/5.00 **综合排名** : 1/322 **英语水平** : CET-4:493
- **主要课程(成绩)** : 科学计算与数据分析(97), 高等数学(96), Java程序设计(96), C语言程序设计(95), 大学物理(95), 数据库原理(93), 计算机视觉基础(92), 计算机网络(91)等
- **获得荣誉** : 校级优秀学生干部(1%), 校级优秀共青团干部(1%), 国家励志奖学金(2%), 校级一等奖学金(5%)

科研经历

1. 农策知音——基于RAG架构的垂直领域农业大模型辅助诊断系统

2024年11月—2025年6月

项目背景:

针对传统农业专家系统交互门槛高、时效性差的问题, 利用LLM结合本地万份农业病虫害手册及农技规程, 构建具备精准问答与病害识别能力的智能助手, 有效缓解垂直领域模型的“幻觉”现象。

项目职责:

(1) 复杂非结构化数据治理: 针对农业手册中存在大量嵌套表格、复杂农药配比表及层级标题的问题, 采用LayoutLMv3与PaddleOCR进行高精度版面分析。构建基于Markdown语义解析的清洗 workflow, 实现文档逻辑结构化, 将数据的有效提取率提升了40%。

(2) RAG检索增强优化: 语义对齐: 引入Query Rewrite纠正农户口语化偏差, 并利用HyDE生成伪回复以缩小查询与文档间的语义鸿沟。搭建基于LangChain的流水线, 引入BGE-Reranker重排序模型对候选文档进行二次筛选, 将检索准确率由基准的65%提升至88%。

(3) 多模态融合方案: 集成CLIP与开源多模态大模型, 实现“拍照识虫+对话建议”的一体化功能, 解决了单一文本检索无法直观诊断病害的痛点。

项目成果:

(1) 建立基于RAGAS的垂直领域评估基准, 系统在忠实度与答案相关性指标上均达到0.92, 在农业专业问答表现上显著优于通用版GPT-4。

(2) 支持100+种农作物的常见病虫害咨询, 已在模拟田间场景完成可行性验证。

2. 轨道交通技术规程智能解析与Agent运维系统

2025年10月—2026年2月

项目背景:

针对轨道交通万级技术标准与运维规程查阅繁琐、响应慢的痛点, 利用LLM的逻辑推理能力, 构建一个能够自动解析复杂维保任务、实时调用监测数据并生成操作检查清单的智能Agent系统。

项目职责:

(1) 领域模型指令微调(SFT): 针对轨道交通专业性强的特点, 选用Qwen-7B及Llama-3-8B作为基座模型, 构建5k+条高质量交通规程指令语料。采用LoRA轻量化微调技术, 强化模型对特定设备结构、故障代码及行业标准的语义对齐。

(2) 多策略Prompt工程: 采用Chain-of-Thought (CoT) 技术优化Prompt模版, 引导模型通过“现状分析—规程检索—逻辑推导—方案生成”的步骤进行多步推理, 有效解决了维保决策中复杂的因果链条问题。

(3) Agent workflow设计: 基于ReAct (Reason+Act) 框架设计Agent逻辑。使系统能够根据故障描述, 自动调用外部API获取列车实时运行数据, 并结合RAG检索到的规程条文, 动态调整排查建议, 实现从“静态检索”到“动态运维”的转变。

项目成果:

(1) 业务赋能: 实现复杂故障处置方案的分钟级自动生成。经业务方实测, 辅助决策效率提升60%, 方案初稿的专家评审采纳率达85%。

(2) 模型性能: 经过领域指令微调, 模型在交通专业术语的理解准确率大幅提升, 显著降低了基座模型在垂直领域的幻觉率。

3. 基于大模型的企业级自然语言交互数据查询(NL2SQL)系统

2025年06月—2025年10月

项目背景:

针对业务人员不具备SQL编写能力导致取数效率低、IT报表需求堆积的问题, 开发基于大模型的Text-to-SQL系统。通过自然语言转化高性能SQL, 实现“对话即报表”, 降低非技术人员的数据消费门槛。

项目职责:

(1) Schema链接增强: 针对企业级数据库中长表名、字段歧义及多关联键问题, 设计了前置Schema过滤模块

。利用语义匹配技术预先筛选相关表结构与元数据，有效降低了模型生成约**50%**的Token压力，显著提升了模型对复杂Schema的理解稳定性。

(2) 动态**Few-shot**检索策略：建立基于向量数据库的**SQL**示例库。根据用户当前问题的语义，通过向量相似度动态召回最匹配的SQL案例并嵌入Prompt。该方案相比固定示例，将复杂查询的生成成功率提升了**25%**。

(3) 闭环错误自我纠正：引入基于执行反馈的纠错机制。当生成的SQL在数据库引擎执行报错时，系统自动捕捉错误日志并反馈给模型进行二次推理修复。该机制成功修复了约**30%**因语法细微偏差导致的初次生成错误，极大增强了系统的鲁棒性。

项目成果：

(1) 评测指标：在Spider标准数据集及企业模拟业务库上进行双重评测，执行准确率达到**78%**，支持5表以上的复杂Join关联及多层嵌套聚合查询。

(2) 业务价值：实现了取数需求的自助化，在模拟业务环境下，相较于传统人工提数流程，数据获取效率提升了**3倍以上**。

竞赛获奖

●2024 全国大学生数学建模 国家级二等奖（担任队长）	2024年10月
●第十届团体程序设计天梯赛 国家级三等奖（核心成员）	2025年05月
●第十六届蓝桥杯大赛 C/C++ B 组 国家级三等奖（个人赛）	2025年06月
●第十八届中国大学生计算机设计大赛 国家级三等奖（核心成员）	2024年07月
●第十届全国大学生物理实验竞赛 国家级三等奖（担任队长）	2024年11月
●第十四届挑战杯大学生创业计划竞赛 省级特等奖（核心成员）	2024年07月
●中国国际“互联网+”大学生创新创业大赛 省银奖（核心成员）	2024年11月
●第九届 HBCPC 河北省大学生程序设计竞赛 铜奖（担任队长）	2025年05月

专业技能

1、大模型系统与算法设计：精通 NLP 基础理论，深入理解 RAG 全链路架构。熟练掌握 Query Rewrite、HyDE 等检索优化策略，并能利用 RAGAS/TruLens 等框架建立多维度算法评估体系。

2、模型训练与偏好对齐：熟练掌 SFT 全流程，精通 LoRA、QLoRA 等 PEFT 技术。深入应用 Llama 全系列（v2/v3/v3.1/v3.2）、通义千问 Qwen 全系列（1.5/2.0/2.5/Math/VL）及 GLM/ChatGLM 系列基座模型。理解 RLHF 逻辑，掌握 DPO 与 PPO 算法，具备模型回复一致性与价值观对齐的实战经验。

3、多模态与计算机视觉：具备丰富的图文融合经验，熟悉 CLIP、LLaVA、Qwen-VL 等多模态大模型的架构与应用。精通图像特征提取（ResNet/Vision Transformer）、目标检测（YOLO 全系列）、OCR（PaddleOCR/EasyOCR）及复杂版面分析（LayoutLMv3）。

4、工程化部署与量化：熟练使用 PyTorch 进行算法实现。具备 FastAPI/Flask 高并发接口开发经验，熟悉 vLLM、TGI 等推理加速框架。掌握 GPTQ、AWQ、GGUF 等模型量化压缩技术，能够保障大模型在生产环境下的低延迟运行。

5、复杂数据治理与工具：擅长非结构化文档预处理，构建了基于 Markdown 语义解析的自动化清洗工作流。熟练使用 OpenCV、PIL 进行图像增强，以及 LangChain、LlamaIndex、Jieba 等工具链，能有效解决垂直领域数据质量瓶颈。

社团和组织经历

担任河北农业大学渤海学院学生会执行主席	2024年09月—2025年9月
---------------------	------------------