



刘源哲 男

求职意向：大模型应用开发

手机 17613989798

邮箱 17613989798@163.com

教育背景

太原理工大学（211工程）	大数据技术与工程 硕士	2025-09 至 2028-06
河南工业大学	人工智能 本科	2021-09 至 2025-06

项目经历

基于LangChain+FastAPI的智能笔记助手(RAG知识库+AI写作辅助) 独立完成

项目介绍：智能笔记助手通过 AI 增强的知识管理能力解决个人知识管理痛点，整合笔记管理、智能标签、语义搜索、间隔重复回顾、RAG 智能问答、多格式文档管理六大能力，实现个人知识的高效管理、智能检索与主动复习的一体化服务。致力于降低个人知识管理的人力成本，提升学习与工作的知识复用效率。

技术栈：LangChain、RAG、HyDE、ReAct、MCP、ChromaDB。

个人职责：

- 负责 AI Agent 架构设计：基于 LangChain 框架设计并实现了 RAG 增强的 ReAct 工具调用 Agent，支持多工具联动，包括笔记搜索、今日回顾查询、知识库检索、文档总结等工具，使 AI Agent 能够灵活调用外部工具完成智能问答、业务咨询等复杂任务。
- 负责 RAG 知识库系统设计：设计了完整的 HyDE 优化混合检索方案，支持笔记库与知识库的跨源关联检索，结合 LLM 重排序优化检索结果。同时支持多格式文档的向量化存储，兼容 PDF/PPT/Word/Markdown 等格式。
- 负责长短对话记忆架构设计：设计了 Redis+MySQL 的异构双存储分层记忆架构，短历史 Redis 热缓存实现毫秒级对话响应，长历史 MySQL 永久持久化保证数据永不丢失，内置滑动窗口裁剪与记忆摘要压缩，解决大模型上下文窗口溢出问题，同时支持历史会话的完整回溯。
- 负责智能笔记核心功能开发：实现了异步自动标签分类、AI 内联续写补全、AI 多模式写作助手、艾宾浩斯间隔重复回顾等功能，支持用户高效编辑笔记、自动归类、主动复习，大幅提升笔记管理的效率，解决传统笔记管理效率低、复习难的问题。
- 负责文档管理与交互优化：实现了多格式文档的智能切片与可视化管理，支持上传进度的 SSE 实时反馈，同时实现了 AI 对话、写作的 SSE 流式输出，解决大模型响应延迟问题，实现实时对话效果，通过容错处理优化用户体验。

智能OnCall Agent系统 独立完成

项目介绍：智能OnCall系统通过AI Agent解决团队真实痛点，整合 知识库、对话、运维 三大核心能力，实现 问题自动应答 和 故障智能排查 的一体化服务。致力于降低团队OnCall的人力成本，提升团队效率。

技术栈：LangChain、LangGraph、RAG、ReAct、Plan-Executor、Multi-Agent、MCP

个人职责：

- 负责 AI Agent 架构设计：基于 LangChain 框架设计并实现了多个AI Agent，包括 Knowledge Index Agent、Chat ReAct Agent 和 Plan-Execute-Replan Agent，通过图编排实现模块化的 Agent 工作流。设计并实现了多工具集成方案，包括通过 MCP 协议集成日志查询工具、Prometheus 告警查询工具、MySQL 数据操作工具、联网查询等，使 AI Agent 能够灵活调用外部工具完成复杂任务。
- 负责 RAG 知识库系统设计：设计了完整的 文档向量化存储和检索方案，支持内部文档的智能检索增强生成。使 AI 能够基于内部知识库提供准确的业务咨询和技术支持。在 RAG 系统中，需要处理文档分割大小和检索TopK参数的选择。分割过小会丢失上下文，过大会降低检索精度；TopK 过大会影响性能，过小可能遗漏关键信息。经过测试验证，确定了最优参数组合，知识检索准确率达到 85%+
- 负责对话功能开发：基于 ReAct 模式实现了对话Agent。实现业务咨询、告警自救、工单预处理等场景无缝切换，一次开发覆盖研发、运维、业务方多角色需求，支持多轮对话上下文记忆，并通过容错处理优化体验。同时基于 SSE技术实现AI对话流式输出，解决大模型响应延迟问题，前端呈现实时对话效果。
- 负责AIOps功能开发：基于 Plan-Execute-Replan 模式 实现了 智能运维Agent。实现了 根据告警信息 → 检索知识库 → 规划执行步骤 → 调用工具查询 → 分析结果 → 生成建议 的完整业务流程，解决了传统运维需要人工排障的低效问题，将运维响应时间从小时级降低到分钟级。能够自动根据内部文档查询监控信息和日志信息，通过工具调用实现自动化监控告警查询和日志分析，并结合历史工单生成运维建议方案。

个人技能

熟悉大模型应用开发流程，了解从Prompt设计、模型调用、上下文构建、工具接入到服务化部署的完整链路，具备RAG与Agent应用开发经验。

熟悉RAG核心流程，包括数据清洗、Chunk切分、Embedding向量化、向量数据库存储、语义检索，混合检索、Rerank、上下文压缩和答案生成等环节。

熟悉LangChain等大模型开发框架，了解Chain、Retriever、Tools、Agent、Memory、Prompt Template 等核心组件的设计与用法。

熟悉Python、FastAPI后端开发流程，能够完成大模型应用接口设计、业务逻辑开发、SSE流式输出、会话管理和日志的落地集成。

熟悉MySQL、Redis、ChromaDB 等数据库和中间件，了解向量数据库在知识检索和语义搜索场景中的使用方式。

资格证书

CET-6 中级软件工程师证书