



李子昊

✉ liziar7@gmail.com ☎ 18302774840 📍 北京 🌐 技术博客

教育经历

北京交通大学

软件工程 软件工程学院

硕士

北京 ▪ 2026年09月 - 2029年06月

中南民族大学

人工智能 计算机科学学院

武汉 ▪ 2021年09月 - 2025年06月

专业技能

Go 后端开发

熟练使用 Go，能够完成分层服务、权限鉴权、并发任务调度及实时通信模块设计。

Gin, GORM, RESTful API, JWT, goroutine, SSE, WebSocket

AI Agent 技术栈

具备 AI Agent 系统设计与落地经验：围绕模型-工具-观察闭环构建 Agent Loop，通过任务规划及 MCP / Tool Calling 接入外部能力，结合 RAG、短期/长期记忆与四层上下文压缩管理知识和长会话；采用 Orchestrator 组织多智能体协作，并通过 Token 预算、工具权限、结构化输出及失败回退保障复杂任务稳定执行。

数据与工程化

熟悉 Python 异步 AI 服务、关系型数据库、缓存、对象存储及 Docker/Linux 部署，具备前后端协作经验。

PostgreSQL, MySQL, SQL Server, Redis, COS / S3, Docker, Linux, Git, Python, FastAPI, asyncio

项目经历

基于 RAG 的智能个性化教学系统

<https://github.com/kidoom/RAG-MCP>

- 设计 Go + Python 双栈架构，Go (Gin/GORM) 负责教学业务（教师、学生、班级、试卷、知识点 CRUD 及千级知识点树形管理），Python 负责 RAG 检索引擎与 MCP 协议服务，两套系统通过 MCP 协议解耦集成。
- 实现五阶段智能数据摄取流水线（Load → Split → Transform → Embed → Upsert），将教学文档、知识点、试题自动解析、语义切分并注入 LLM 增强元数据，以 Dense + BM25 双路向量化存储至 ChromaDB。
- 构建 Hybrid Search 混合检索引擎，粗排阶段并行执行 Dense Embedding 与 BM25 检索，通过 RRF 融合双路结果；精排阶段支持 Cross-Encoder / LLM Rerank 可插拔切换，失败时自动回退至融合排名。
- 基于 MCP (JSON-RPC 2.0 + Stdio Transport) 实现知识检索 Server，支持 Copilot / Claude Desktop 即插即用；采用工厂模式 + YAML 配置驱动，LLM / Embedding / VectorStore / Reranker 支持 OpenAI、Ollama、DeepSeek 等 4 类 Provider 零代码切换。
- 建立自动化评估框架，实现 CustomEvaluator (Hit Rate / MRR) 与 RAGAS (Faithfulness / Answer Relevancy) 双评估后端，支持 Golden Test Set 回归测试；基于 Streamlit 构建六页面管理平台，覆盖数据浏览、摄取管理、链路追踪与评估面板。

AI 智能代码审查助手 - PR Copilot

2025.03 - 2025.06 | 独立开发者

背景：在软件开发团队中，Code Review 耗时长、覆盖面有限，安全漏洞和测试遗漏频发。传统人工审查难以应对多文件联动变更和跨模块影响分析，关键风险常在合并后才被发现，修复成本高昂。

目标：设计并实现基于 Multi-Agent 协同的智能代码审查系统，通过确定性规则引擎与 AI Agent 双轨分析，实现安全检测、测试覆盖、配置审查、代码质量四维度自动化深度分析，将 PR 审查覆盖率提升至全维度覆盖，反馈延迟控制在分钟级。

- 设计 security-reviewer / test-context-analyzer / config-reviewer / code-quality-reviewer 四专业 Agent 协同审查架构，基于 OM A 框架实现 Orchestrator 统一调度与结果合成，每个 Agent 拥有独立系统 Prompt、工具白名单和 128K-256K 差异化上下文窗口。
- 实现两层 DAG 任务规划引擎：静态层基于 10 条证据规则自动提取风险信号，按类型聚合为 security-review / code-quality / test-coverage / config-review 四类任务，结合文件优先级评分和 Token 预算生成定向审查计划；动态层由 Coordinator 将审查目标分解为可并行执行的子任务 DAG，分配给对应专业 Agent，支持重试控制 (maxRetries=2、指数退避) 和失败降级。
- 构建 Token 感知的审查打包机制，根据每个 Agent 的作用域自动裁剪 Diff 切片、限定文件白名单和搜索路径，结合 Repair / Micro Compact / AutoCompact / Recent 四层上下文压缩策略，确保 128K Token 窗口内关键证据不丢失。
- 设计多维度文件分类与优先级评分系统，30+ 文件扩展名映射到语言和规则配置，基于路径风险、变更规模、文件状态、语言风险四因子加权公式自动划分 must_review / should_review / skim 三级优先级，确保关键文件优先获得深度审查资源。
- 集成 SSE + WebSocket 双通道实时推送，支持单调序列号去重、断线重连事件重放、晚到客户端缓冲，确保审查过程全链路可观测。

结果：系统上线后，单次 PR 审查覆盖 4 个专业维度，10 条确定性规则自动扫描风险信号并生成定向任务，Coordinator DAG 编排支持 4 Agent 并行分析与自动重试，30+ 文件类型自动分类与三级优先级评分确保审查资源精准分配，审查反馈通过 SSE + WebSocket 实时推送延迟低于秒级。